

CLIP

📅 date	2026년 9월 24일
≡ 유형	BOAZ 학기 4주차 (1)

CLIP: Learning Transferable Visual Models From Natural Language Supervision

Background

핵심 용어

기존 방식 vs CLIP

Abstract

1. Introduction and Motivating Work

2. Approach

2.1 Natural Language Supervision

2.2 Creating a Sufficiently Large Dataset

2.3 Selecting an Efficient Pre-Training Method

2.4 Choosing and Scaling a Model

2.5 Training

3. Experiments

3.1 Zero-Shot Transfer

3.1.1 Motivation

3.1.2 Using CLIP for Zero-Shot Transfer

3.1.3 Initial Comparison to Visual N-Grams

3.1.4 Prompt Engineering and Ensembling

3.1.5 Analysis of Zero-Shot CLIP Performance

3.2 Representation Learning

3.3 Robustness to Natural Distribution Shift

4. Comparison to Human Performance

5. Data Overlap Analysis

6. Limitations

7. Broader Impacts

7.1 Bias

7.2 Surveillance

7.3 Future Work

8. Related Work

9. Conclusion

Appendix 핵심 요약

A. Linear-probe evaluation

B. Zero-Shot Prediction (Table 11)

C. Duplicate Detector

D. Dataset Ablation on YFCC100M (Table 12)

E. Selected Task Results

CLIP: Learning Transferable Visual Models From Natural Language Supervision

Background

핵심 용어

용어	의미
Natural language supervision	고정된 클래스 라벨 대신, 이미지와 짝지어진 자연어 텍스트를 학습 신호로 사용
Contrastive learning	맞는 쌍은 임베딩을 가깝게, 틀린 쌍은 멀게 학습
Zero-shot transfer	해당 데이터셋으로 학습 없이 바로 평가. 여기서는 "unseen 클래스"가 아니라 unseen 데이터셋 으로의 일반화를 뜻함
Linear probe	인코더는 고정하고, 그 위에 로지스틱 회귀(선형 분류기)만 학습해서 표현의 품질을 측정
Effective robustness	ImageNet 정확도로 예측되는 수준을 넘어선 distribution shift 성능 향상
WIT (WebImageText)	논문이 직접 구축한 4억 개 (image, text) 쌍 데이터셋

기존 방식 vs CLIP

- 기존 vision 모델: image encoder + **고정된 softmax 분류기** → 정해진 클래스 집합(예: 1000개)만 예측 가능. 새 개념을 추가하려면 라벨링 데이터가 다시 필요
- CLIP: image encoder + text encoder를 함께 학습 → 테스트 시 클래스 이름(텍스트)을 넣으면 **분류기가 즉석에서 생성됨**
- 결과적으로 클래스 집합이 고정되지 않음. 텍스트로 쓸 수 있는 개념이면 무엇이든 분류 대상이 됨

Abstract

- 기존 SOTA vision 시스템은 **미리 정해진 고정 클래스 집합**을 예측하도록 학습됨 → 다른 시각 개념을 다루려면 추가 라벨 데이터가 필요해서 범용성이 제한됨
- 대안: 이미지에 대한 raw text에서 직접 학습 → 훨씬 넓은 범위의 supervision 활용 가능
- 사전학습 과제는 단순함: "**어떤 캡션이 어떤 이미지와 짝인가**"를 맞추는 것
- 인터넷에서 수집한 **4억 개 (image, text) 쌍**으로 처음부터(from scratch) 학습
- 사전학습 후 자연어로 시각 개념을 참조/기술 → 다운스트림 태스크로 **zero-shot transfer**
- OCR, 비디오 행동 인식, geo-localization, 세밀한 객체 분류 등 **30개 이상** 데이터셋으로 벤치마크
- 데이터셋별 학습 없이도 완전 지도학습 baseline과 경쟁 가능
- 예: ImageNet zero-shot 정확도가 원래 ResNet-50과 동일 (128만 장 학습 데이터를 하나도 안 씀)
- 코드와 가중치 공개: <https://github.com/OpenAI/CLIP>

1. Introduction and Motivating Work

1) 배경: NLP에서의 성공

- NLP에서는 raw text로 직접 사전학습하는 방식이 혁명을 일으킴 (autoregressive, masked LM 등)

- "text-to-text"라는 표준 입출력 인터페이스 덕에 task-agnostic 아키텍처가 **전용 output head 없이 zero-shot transfer** 가능
- GPT-3 같은 모델은 데이터셋 전용 학습 데이터가 거의 없어도 특화 모델과 경쟁
- 시사점: 웹 규모 텍스트의 총 supervision이 고품질 크라우드 라벨링 데이터셋(NLP)을 능가
- 반면 vision은 여전히 ImageNet 같은 crowd-labeled 데이터셋으로 사전학습하는 게 표준
- 핵심 질문: **웹 텍스트에서 직접 학습하는 scalable 사전학습이 vision에서도 같은 돌파구를 만들 수 있는가?**

2) 선행 연구와 한계

- Mori et al. (1999): 이미지 검색을 위해 문서 속 명사/형용사 예측
- Quattoni et al. (2007), Srivastava & Salakhutdinov (2012): 캡션 단어 예측 기반 표현 학습
- Joulin et al. (2016): 캡션/제목/해시태그를 bag-of-words 다중 라벨 문제로 바꿔 CNN 사전학습
- Li et al. (2017) Visual N-Grams: 최초로 표준 데이터셋에 zero-shot transfer를 시도했으나 ****ImageNet zero-shot 11.5%****에 그침
- VirTex, ICMLM, ConVIRT: transformer / masked LM / contrastive 목적함수로 가능성을 입증했으나 규모가 작음

3) 왜 잘 안 쓰였나 → 성능이 낮았기 때문

- Li et al. (2017)의 11.5%는 당시 SOTA 88.4%, 심지어 고전적 CV 방법의 50%보다도 낮음
- 대신 **좁지만 잘 겨냥된 약지도(weak supervision)** 방식이 성과를 냄
 - Mahajan et al. (2018): Instagram 해시태그 예측으로 사전학습 → ImageNet 정확도 5%+ 향상
 - Kolesnikov et al. (2019), Dosovitskiy et al. (2020): JFT-300M의 noisy 라벨 클래스 예측
- 이 방식의 타협점: supervision을 **1000개 / 18291개 클래스로 제한**, 고정 softmax 분류기라 dynamic output 불가 → zero-shot 능력이 크게 제한됨

4) 핵심 차이는 "규모"

- Mahajan, Kolesnikov: 수백만~수십억 장, **accelerator-years** 단위 학습
- VirTex, ICMLM, ConVIRT: 10~20만 장, **accelerator-days** 단위 학습
- 이 논문: 4억 쌍 데이터셋을 만들고, ConVIRT의 단순화 버전을 from scratch로 학습 → **CLIP (Contrastive Language-Image Pre-training)**
- 8개 모델을 약 2 orders of magnitude 컴퓨트 범위로 학습 → **transfer 성능이 compute의 함수로 부드럽게 예측 가능**
- GPT처럼 사전학습 중에 OCR, geo-localization, action recognition 등 다양한 태스크를 학습

5) 논문의 주요 주장 (Introduction 마지막)

- 30개+ 데이터셋 zero-shot: 태스크 특화 지도학습 모델과 경쟁 가능
- Linear probe 분석: 공개된 최고 ImageNet 모델보다 성능이 좋고 계산 효율도 높음
- Zero-shot CLIP은 동등한 정확도의 지도학습 ImageNet 모델보다 **훨씬 robust함** → zero-shot 평가가 모델의 실제 능력을 더 잘 반영한다는 시사
- 정책적/윤리적 함의는 Section 7에서 다룸

2. Approach

2.1 Natural Language Supervision

1) 핵심 아이디어

- 자연어에 담긴 supervision으로부터 perception을 학습
- 새로운 아이디어는 아님. 다만 기존 연구들이 자기 방법을 unsupervised / self-supervised / weakly supervised / supervised 등으로 다르게 불러서 용어가 혼란스러웠음
- 이 논문의 입장: 세부 방법이 아니라 "**자연어를 학습 신호로 쓴다**"는 점이 공통이므로 전부 natural language supervision으로 통칭

2) 장점

- **확장이 쉬움**: 1-of-N majority vote 같은 "ML 호환 포맷" 라벨링이 필요 없음. 인터넷 텍스트에서 수동적으로 학습 가능
- unsupervised/self-supervised와 달리 **표현을 언어와 연결**해 주므로 flexible zero-shot transfer가 가능

2.2 Creating a Sufficiently Large Dataset

1) 기존 데이터셋의 한계

데이터셋	규모	문제
MS-COCO	약 10만 장	고품질이지만 현대 기준으로 작음
Visual Genome	약 10만 장	위와 동일
YFCC100M	1억 장	메타데이터가 희박하고 품질이 들쭉날쭉 (20160716_113957.JPG 같은 자동 파일명). 영어 자연어 필터링 후 약 1500만 장 으로 축소 (ImageNet과 비슷한 규모)

2) WIT 구축

- 다양한 공개 인터넷 소스에서 **4억 개 (image, text) 쌍** 수집
- 최대한 넓은 시각 개념을 커버하려고 **50만 개 쿼리** 중 하나가 텍스트에 포함된 쌍을 검색
 - 쿼리 리스트: 영어 Wikipedia에서 100번 이상 등장하는 모든 단어 + 높은 PMI의 bi-gram + 검색량 높은 Wikipedia 문서 제목 + WordNet synset
- 쿼리당 **최대 20,000쌍**으로 approximate class balance
- 총 단어 수가 GPT-2 학습에 쓴 WebText와 비슷

2.3 Selecting an Efficient Pre-Training Method

1) 문제의식: 효율이 핵심

- SOTA vision 시스템은 컴퓨트 소모가 매우 큼 (ResNeXt101-32×48d: 19 GPU-years, Noisy Student EfficientNet-L2: 33 TPUv3 core-years)
- 이걸 겨우 1000개 클래스를 예측하는 데 든 비용 → 열린 집합의 시각 개념을 자연어로 학습하는 건 더 막막함
- 그래서 **학습 효율을 기준으로 최종 방법을 선택**

2) 세 가지 접근의 비교 (Figure 2)

!Figure 2 요약

방법	내용	ImageNet zero-shot 학습 효율
① Transformer LM (VirTex 유사)	이미지 CNN + 텍스트 transformer로 캡션을 그대로 생성	기준선 (가장 느림)
② Bag-of-Words prediction	텍스트의 BoW 인코딩을 예측	①보다 3배 효율적
③ BoW contrastive (CLIP)	예측 대신 contrastive 목적함수	②보다 추가 4배 효율적

- ①의 63M 파라미터 transformer LM은 ResNet-50 이미지 인코더의 2배 컴퓨트를 쓰는데도 ImageNet 클래스 인식을 3배 느리게 학습함
- ①②의 공통 문제: **텍스트의 정확한 단어를 예측**하려 함 → 이미지와 함께 등장하는 설명/댓글/관련 텍스트가 너무 다양해서 어려운 과제
- 근거 연구: contrastive 목적함수가 predictive 목적함수보다 더 좋은 표현을 학습 (Tian et al., 2019), generative 모델은 같은 성능에 10배 이상의 컴퓨트가 필요 (Chen et al., 2020a)
- 결론: "정확한 단어"가 아니라 "어떤 텍스트 전체가 어떤 이미지와 짝인가"라는 더 쉬운 **proxy task**를 푼다

3) CLIP의 학습 목표

- 배치의 N 개 (image, text) 쌍이 주어졌을 때, $N \times N$ 가능한 조합 중 **실제 짝을 맞추도록** 학습
- image/text 인코더를 함께 학습해 **N 개 정답 쌍의 cosine similarity는 최대화, 나머지 $N^2 - N$ 개 오답 쌍은 최소화**
- **symmetric cross entropy loss**를 사용
- 이 batch 구성과 목적함수의 계보
 - multi-class N-pair loss (Sohn, 2016) → InfoNCE loss (Oord et al., 2018) → 의료 영상에서 (text, image)에 적용 (ConVIRT, Zhang et al., 2020)

4) 핵심 의사코드 (Figure 3)

```
# 각 modality의 feature 추출
I_f = image_encoder(I) # [n, d_i]
T_f = text_encoder(T)  # [n, d_t]

# joint multimodal embedding [n, d_e]
I_e = l2_normalize(np.dot(I_f, W_i), axis=1)
T_e = l2_normalize(np.dot(T_f, W_t), axis=1)

# scaled pairwise cosine similarities [n, n]
logits = np.dot(I_e, T_e.T) * np.exp(t)

# symmetric loss
labels = np.arange(n)
loss_i = cross_entropy_loss(logits, labels, axis=0)
loss_t = cross_entropy_loss(logits, labels, axis=1)
loss = (loss_i + loss_t) / 2
```

- W_i, W_t : 각 인코더 출력을 공통 임베딩 공간으로 보내는 **선형 projection**
- L2 normalize를 했으므로 내적 = cosine similarity
- t : 학습되는 temperature ($\text{np.exp}(t)$ 로 로짓 스케일링)
- 라벨은 $\text{arange}(n)$ → 대각선(i 번째 이미지 ↔ i 번째 텍스트)이 정답
- 이미지 방향(행)과 텍스트 방향(열) 양쪽으로 cross entropy를 구한 뒤 평균

5) ConVIRT 대비 단순화한 부분

- ImageNet 가중치나 사전학습된 텍스트 가중치 없이 **from scratch** 학습 (데이터가 커서 overfitting은 큰 걱정이 아님)
- 표현과 contrastive 임베딩 공간 사이에 **non-linear projection 대신 linear projection**만 사용 (학습 효율 차이 없음. non-linear는 self-supervised에서만 co-adapt됐을 것으로 추정)

- 텍스트에서 문장 하나를 샘플링하는 변환 t_u 제거 (대부분 단일 문장이라서)
- 이미지 augmentation은 **random square crop**만 사용
- temperature τ 는 하이퍼파라미터 튜닝 대신 **log-parameterized** 곱셈 스칼라로 직접 학습

2.4 Choosing and Scaling a Model

1) Image encoder (2가지)

- **ResNet-50 (수정판)**
 - ResNet-D 개선 (He et al., 2019) + antialiased rect-2 blur pooling (Zhang, 2019)
 - global average pooling을 **attention pooling**으로 교체
 - 단일 층 "transformer-style" multi-head QKV attention, query는 이미지의 global average-pooled 표현으로 조건화
- **Vision Transformer (ViT)**
 - 원 구현을 거의 그대로 따르되, patch + position embedding 결합 뒤에 **LayerNorm 하나 추가**, 초기화 방식만 약간 다름

2) Text encoder

- Transformer (Radford et al., 2019의 수정 아키텍처)
- 기본 크기: **63M 파라미터, 12층, width 512, 8 heads**
- lower-cased BPE 표현, **vocab 49,152**, 최대 시퀀스 길이 **76**
- 텍스트를 **[SOS]**, **[EOS]** 토큰으로 감싸고, 최상위 층의 **[EOS]** 위치 **activation**을 텍스트 feature로 사용 → LayerNorm → 선형 projection으로 공통 임베딩 공간에 매핑
- Masked self-attention 사용 (사전학습된 LM으로 초기화하거나 보조 LM 목적함수를 추가할 여지를 남기기 위함. 탐색은 future work)

3) 스케일링 방식

- 기존 vision 연구: width만(Mahajan) 또는 depth만(He) 키움
- 여기서는 EfficientNet (Tan & Le, 2019)의 접근을 채택 → width, depth, resolution 전부에 컴퓨트를 배분
- EfficientNet은 세 차원의 비율을 튜닝하지만, CLIP은 **세 차원에 동등하게 배분**하는 단순 baseline 사용
- 텍스트 인코더는 **width만** ResNet의 width 증가에 비례해 키우고 depth는 고정 (CLIP 성능이 텍스트 인코더 용량에 덜 민감했기 때문)

2.5 Training

1) 학습한 모델

- **ResNet 5개**: RN50, RN101, 그리고 RN50 대비 약 4x/16x/64x 컴퓨트인 **RN50×4, RN50×16, RN50×64**
- **ViT 3개**: ViT-B/32, ViT-B/16, ViT-L/14

2) 학습 설정

항목	값
Epochs	32
Optimizer	Adam + decoupled weight decay (gain/bias 제외한 모든 가중치)
LR schedule	cosine decay
Batch size	32,768 (매우 큼)
Temperature τ	0.07에 해당하는 값으로 초기화, 로짓 스케일이 100을 넘지 않게 clip (학습 불안정 방지)

항목	값
메모리/속도	mixed-precision, gradient checkpointing, half-precision Adam statistics, half-precision stochastically rounded text encoder 가중치
유사도 계산	GPU마다 자기 로컬 배치에 필요한 pairwise similarity 부분만 계산 (sharding)

3) 학습 비용

- 가장 큰 ResNet (RN50×64): **592개 V100, 18일**
- 가장 큰 ViT: **256개 V100, 12일**

4) 최종 모델 "CLIP"

- ViT-L/14를 **336px 해상도로 1 epoch 추가 사전학습** (FixRes와 유사한 성능 향상 기법) → **ViT-L/14@336px**
- 논문 전체에서 "CLIP"이라고 하면 별도 명시가 없는 한 이 모델을 뜻함 (가장 성능이 좋았음)

3. Experiments

3.1 Zero-Shot Transfer

3.1.1 Motivation

- CV에서 zero-shot은 원래 "unseen 객체 **카테고리**로의 일반화"를 뜻함
- 이 논문은 더 넓게 "unseen 데이터셋으로의 일반화"를 의미 → unseen **태스크**를 수행하는 능력의 proxy
- 비교: unsupervised learning은 표현 학습 능력에 초점, zero-shot은 **task-learning** 능력을 측정
- 단서: CIFAR-10 같은 데이터셋은 "어떤 실제 태스크를 재는지" 불분명하고, 이런 경우 zero-shot은 태스크 일반화보다 **distribution shift / domain generalization** 평가에 가까움 (→ Section 3.3)
- NLP 쪽 영감: Liu et al. (2018)이 언어모델이 위키 문서를 생성하다 이름 번역을 학습하는 현상을 "unexpected side-effect"로 발견 → GPT-2가 zero-shot task learning을 본격 연구

3.1.2 Using CLIP for Zero-Shot Transfer

1) 절차

- 데이터셋의 **모든 클래스 이름**을 텍스트 후보로 사용
- 이미지 임베딩과 텍스트 후보 임베딩을 각 인코더로 계산
- cosine similarity → temperature τ 로 스케일링 → **softmax로 확률화**
- 가장 확률이 높은 (image, text) 쌍을 예측

2) 해석: 텍스트 인코더 = hypernetwork

- 이 예측 레이어는 **L2 정규화된 입력, L2 정규화된 가중치, bias 없음, temperature 스케일링**을 가진 multinomial logistic regression
- image encoder = vision backbone (feature 계산)
- text encoder = **hypernetwork** (Ha et al., 2016), 클래스를 설명하는 텍스트로부터 **선형 분류기의 가중치를 생성**
- 이 관점에서 CLIP 사전학습의 매 스텝은 "클래스당 예제 1개, 자연어로 정의된 32,768개 클래스를 가진 랜덤 생성 CV 데이터셋"의 성능을 최적화하는 것
- 평가 시에는 zero-shot 분류기를 **한 번 계산해 캐시**하고 재사용 → 생성 비용이 전체 예측에 amortize됨

3.1.3 Initial Comparison to Visual N-Grams

Table 1

	aYahoo	ImageNet	SUN
Visual N-Grams	72.4	11.5	23.0
CLIP	98.4	76.2	58.5

- ImageNet: **11.5% → 76.2%**, 원래 ResNet-50과 동일 성능 (128만 학습 샘플 미사용)
- Top-5 정확도 95%로 Inception-V4와 동일
- aYahoo: 오류 95% 감소, SUN: 정확도 2배 이상
- 단서: 이는 **직접적인 방법 비교가 아님** (데이터 10배, 예측당 컴퓨터 약 100배, 학습 컴퓨터 1000배 이상, transformer 사용 등 통제되지 않은 차이 다수)
- 더 가까운 비교: **CLIP ResNet-50을 YFCC100M으로 학습시키면 Visual N-Grams의 ImageNet 성능을 V100 1 GPU-day 이내에 맞춥니다**

3.1.4 Prompt Engineering and Ensembling

1) 문제: 클래스 이름만으로는 부족

- 많은 데이터셋이 클래스를 숫자 ID로만 라벨링하고 영어 이름 매핑을 부수적으로 제공 (Flowers102, GTSRB는 아예 매핑이 없어 zero-shot이 불가능)
- **Polysemy(다의어)**: 클래스 이름만 주면 어떤 뜻인지 구분 불가
 - ImageNet에 crane(건설 기중기)과 crane(새)가 둘 다 존재
 - Oxford-IIIT Pet의 boxer(개 품종) vs 운동선수
- **분포 갭**: 사전학습 데이터에서 텍스트는 대개 단어 하나가 아니라 이미지를 설명하는 **문장**

2) 해결 1: Prompt template

- 기본 템플릿 **"A photo of a {label}."** → ImageNet에서만 **+1.3%**
- 태스크별 커스터마이징 (GPT-3 prompt engineering과 유사)
 - Oxford-IIIT Pets: "A photo of a {label}, a type of pet."
 - Food101: a type of food / FGVC Aircraft: a type of aircraft
 - OCR 데이터셋: 인식할 텍스트/숫자에 따옴표
 - 위성 이미지: "a satellite photo of a {label}."

3) 해결 2: Ensembling

- "A photo of a big {label}", "A photo of a small {label}" 등 여러 프롬프트로 만든 분류기를 앙상블
- **확률 공간이 아니라 임베딩 공간에서** 앙상블 → 평균 텍스트 임베딩을 하나만 캐시하면 되므로 컴퓨터 비용이 단일 분류기와 동일
- ImageNet: **80개 프롬프트** 앙상블로 단일 프롬프트 대비 **+3.5%**
- Prompt engineering + ensembling 합치면 ImageNet **약 +5%** (Figure 4: 36개 데이터셋 평균 약 5점 향상, 컴퓨터 4배 증가와 맞먹는 효과이나 "공짜")

3.1.5 Analysis of Zero-Shot CLIP Performance

1) vs 완전 지도학습 baseline (Figure 5)

- baseline: ResNet-50 feature 위에 학습한 regularized logistic regression
- **27개 중 16개 데이터셋에서 zero-shot CLIP이 앞섬**

구분	데이터셋	결과
크게 우세	Stanford Cars (+28.9), Country211 (+23.2), Food101 (+22.5)	20점 이상 차이

구분	데이터셋	결과
행동 인식	Kinetics700 (+14.5), UCF101 (+7.7)	자연어가 동사 개념까지 폭넓게 supervision → 추정
일반 객체	ImageNet, CIFAR10/100, STL10, VOC2007	근소하게 우세. STL10은 99.3%로 새 SOTA
크게 열세	Flowers102, FGVC Aircraft	10점 이상 낮음
매우 열세	EuroSAT (-37.1), KITTI Distance (-34.0), PatchCamelyon, CLEVRCounts, GTSRB 등	특수/복잡/추상적 태스크에서 약함

- 세밀한 분류에서 격차가 갈리는 이유는 WIT와 ImageNet의 **태스크별 supervision 양 차이** 때문으로 추정

2) 어려운 태스크에서의 한계

- 위성 사진 분류, 림프절 종양 탐지, 합성 장면 물체 세기, 독일 교통표지, 자동차와의 거리 인식 등에서 약함
- 다만 이런 태스크는 인간 비전문가도 잘하는 것(세기, 위성 분류, 교통표지)도 있어 개선 여지가 큼
- 단서: 림프절 종양처럼 **사람도 사전 경험이 없는 태스크**에서 zero-shot이 의미 있는 평가인지는 불분명

3) vs Few-shot (Figure 6)

- 직관: zero-shot은 one-shot보다 못할 것 같음 → 실제로는 **zero-shot CLIP $\approx$ 4-shot logistic regression** (같은 feature 공간)
- 이유 (추정)
 - zero-shot 분류기는 자연어로 개념을 **직접 지정("communicate")**
 - 일반 지도학습은 예제로부터 개념을 **간접적으로 추론**해야 하는데, 한 이미지에 여러 개념이 들어 있어 one-shot 같은 경우 가설이 여러 개 성립
- Few-shot이 zero-shot을 못 따라가는 현상의 해결책 후보: zero-shot 분류기를 few-shot 가중치의 **prior**로 쓰기 (L2 penalty로 구현해 봤지만, 하이퍼파라미터 최적화가 정규화를 너무 세게 잡아 결국 "그냥 zero-shot 분류기"가 됨 → future work)
- 다른 모델 feature 위의 few-shot과 비교하면, zero-shot CLIP은 **최고 성능 16-shot 분류기(BiT-M ResNet-152 $\times$ 2, ImageNet-21K)**와 대략 동등

4) Data efficiency (Figure 7)

- 같은 CLIP feature 공간에서 zero-shot과 같은 성능을 내려면 클래스당 몇 개의 라벨 데이터가 필요한가?
- 로그-선형 보간으로 추정: **평균 20.8개, 중앙값 5.4개**
- 데이터셋별 편차가 큼: 1개 미만(Flowers102, EuroSAT은 one-shot보다 못함) ~ **184개**까지
- 평균이 중앙값보다 훨씬 큰 이유는 상위 20% 데이터셋이 매우 많은 예제를 요구하기 때문
- ImageNet: zero-shot CLIP = 16-shot linear classifier

5) Zero-shot vs 완전 지도학습 linear probe (Figure 8)

- CLIP의 zero-shot 분류기도 선형 분류기이므로, 완전 지도학습 선형 분류기가 **성능의 대략적 상한**을 준다고 볼 수 있음
- 양의 상관관계: $r = 0.82(p < 10^{-6})$
- 대부분 데이터셋에서 zero-shot이 지도 성능보다 **10~25점 낮음**
- 격차가 3점 이내인 것은 STL10, CIFAR10, Food101, OxfordPets, Caltech101 (5개). 모두 정확도 90% 이상
- 회귀 기울기: 지도 성능이 1% 오르면 zero-shot은 **1.28% 오름** (95% CI: 0.93~1.79)

6) Scaling (Figure 9)

- GPT 계열은 1000배 컴퓨트 증가에도 zero-shot 성능이 일관되게 향상

- CLIP: 5개 ResNet CLIP, 39개 평가(36개 데이터셋)에서 평균 오류율이 **44배 컴퓨트 범위에서 log-log 선형 추세**
- 단, 개별 평가는 훨씬 noisy (학습 run 간 분산 D'Amour et al. 2020 때문인지 실제로 비단조인지는 불확실)

3.2 Representation Learning

1) 평가 방식: 왜 linear probe인가

- 대안인 end-to-end fine-tuning이 보통 더 성능이 높지만, linear probe를 택한 이유
 - 목표가 **task/dataset-agnostic 사전학습**의 품질을 보는 것
 - Fine-tuning은 적응 과정에서 사전학습 표현의 **실패를 가려버릴** 수 있음. linear probe는 유연성이 낮아서 실패가 그대로 드러남
 - Zero-shot 분류기와 형태가 비슷해 비교가 쉬움
 - 66개 모델 × 27개 데이터셋 = 1782회 평가에서 하이퍼파라미터 튜닝 부담이 적음

2) 결과 (Figure 10)

평가 스위트	결과
Kornblith et al. 12개 데이터셋	작은 CLIP(RN50, RN101)은 ImageNet-21K BiT-M보다 낮고 EfficientNet 계열보다도 낮음. 그러나 스케일이 커지면 매우 잘 올라가 RN50×64가 Noisy Student EfficientNet-L2를 근소하게 앞섬. 최고 모델 ViT-L/14@336px는 기존 최고 대비 평균 +2.6%
논문이 확장한 27개 데이터셋	모든 CLIP 모델이 컴퓨트 효율 면에서 평가된 모든 시스템을 앞섬. 최고 모델 격차가 **+2.6% → +5%**로 확대

- **CLIP ViT는 CLIP ResNet보다 컴퓨트 효율이 약 3배** (Dosovitskiy et al.의 결과를 재확인)
- 넓은 스위트에서는 self-supervised 시스템이 상대적으로 더 잘 나옴 (SimCLRv2가 12개 스위트에서는 BiT-M보다 낮지만 27개에서는 앞섬)
 - 평가 태스크 다양성을 늘려야 "일반적" 성능을 제대로 알 수 있다는 시사

3) vs Noisy Student EfficientNet-L2 (Figure 11)

- CLIP이 **27개 중 21개**에서 앞섬
- 가장 크게 개선: OCR(SST2, HatefulMememes), geo-localization/장면 인식(Country211, SUN397), 비디오 행동(Kinetics700, UCF101), 세밀한 자동차/교통표지(Stanford Cars, GTSRB +14.7%)
- GTSRB 해석: ImageNet-1K는 모든 교통/도로 표지에 **단일 라벨만** 있어 지도학습 표현이 클래스 내부 디테일을 뭉개 버렸을 가능성
- EfficientNet이 나온 곳: ImageNet (본인이 학습한 데이터), 저해상도(CIFAR10/100 — CLIP에 scale augmentation이 없어서로 추정), PatchCamelyon, CLEVRCounts (둘 다 전체 성능이 낮은 데이터셋)

3.3 Robustness to Natural Distribution Shift

1) 문제 배경

- 2015년 ImageNet 테스트셋에서 인간 성능 초과가 발표되었으나, 이후 새 벤치마크에서는 성능이 크게 떨어지는 것이 반복 확인됨
- 흔한 설명: 모델이 학습 분포에서만 성립하는 **spurious correlation**을 잡음
- 하지만 대부분 **ImageNet 학습 모델만** 연구했음 → 원인이 딥러닝 자체인지, ImageNet인지, 둘의 조합인지 불분명
- CLIP은 다른 각도에서 이 질문을 조사할 기회

2) Taori et al. (2020) 프레임워크

- 7개 **natural** distribution shift 데이터셋 (ImageNetV2, ImageNet-Sketch, YouTube-BB, ImageNet-Vid, ObjectNet, ImageNet-A, ImageNet-R). 합성 shift(ImageNet-C 등)와 구분
- ResNet-101은 이 shift에서 ImageNet 검증셋 대비 **5배 많은 실수**
- **Effective robustness**: in-distribution 정확도로 예측되는 수준(logit 변환 선형 관계) **이상**의 향상
- **Relative robustness**: 단순한 out-of-distribution 정확도 향상

3) Zero-shot CLIP의 결과 (Figure 13)

- 모든 zero-shot CLIP 모델이 effective robustness를 크게 향상, ImageNet 정확도와 shift 정확도 간 "robustness gap"을 **최대 75% 감소**
- 직관: zero-shot 모델은 특정 분포에만 성립하는 spurious pattern을 이용할 수 없음 (단, 사전학습과 평가 분포가 공유하는 상관관계는 이용 가능)

데이터셋	ResNet-101	Zero-shot CLIP (ViT-L/14@336px)
ImageNet	76.2	76.2
ImageNetV2	64.3	70.1
ImageNet-R	37.7	88.9
ObjectNet	32.6	72.3
ImageNet-Sketch	25.2	60.2
ImageNet-A	2.7	77.1

- 두 모델은 ImageNet 검증셋 성능이 동일하게 맞춰진 비교

4) ImageNet에 적응시키면? (Figure 14)

- CLIP feature 위에 ImageNet 학습셋으로 L2 logistic regression 학습
- ImageNet 정확도 **+9.2% → 85.4%** (2018 SOTA와 동률. SOTA 약 3년 치 개선에 해당)
- 그런데 **분포 shift 평균 정확도는 오히려 약간 감소**

데이터셋	변화
ImageNetV2	+5.8 (원래 ImageNet 생성 과정을 따른 데이터라 ImageNet 분포에 가까움)
ImageNet-R	-4.7
ObjectNet	-3.8
ImageNet-Sketch	-2.8
ImageNet-A	-1.9

- 시사점: 지도학습으로 얻은 이득이 **ImageNet 분포 근처에만** 집중됨
- 이 현상의 원인(spurious correlation 활용 여부, CLIP/ImageNet/shift의 특정 조합인지 일반 현상인지)은 **확실한 답이 없다**고 저자들이 인정

5) Class shift에 맞춘 zero-shot 분류기

- YouTube-BB, ImageNet-Vid는 ImageNet 클래스의 superclass라 고정 1000-way 분류기를 쓰기 어려움 (Taori는 max-pooling으로 처리 → 매핑이 불완전한 경우가 있음. 예: person 클래스를 baseball player/bridegroom/scuba diver ImageNet 클래스로 pooling)
- CLIP은 각 데이터셋의 클래스 이름으로 커스텀 zero-shot 분류기를 바로 생성 → 평균 effective robustness **+5%** (소수 데이터셋에 큰 향상이 집중), ObjectNet도 +2.3%

6) Zero-shot → Few-shot → Full supervision 연속체 (Figure 15)

- 0/1/2/4/.../128-shot, 완전 지도학습 비교

- Few-shot도 기존 모델보다 effective robustness가 높지만, **in-distribution 성능이 올라갈수록 이 이점이 줄어** 완전 지도학습에서는 거의(전부는 아님) 사라짐
- 같은 ImageNet 성능의 few-shot 모델보다 zero-shot CLIP이 훨씬 robust

7) 정리

- 높은 effective robustness는 **분포에 특화된 학습 데이터에 덜 노출될수록** 얻어지지만, 데이터셋 특화 성능을 희생함
- 대규모 task/dataset-agnostic 사전학습 + zero-shot/few-shot 벤치마킹이 더 robust한 시스템과 더 정확한 성능 평가로 이어진다는 주장 (Yogatama, Linzen 등이 옹호한 방향)

4. Comparison to Human Performance

1) 실험 설계

- Oxford IIIT Pets (37개 고양이/개 품종) 테스트셋 **3,669장**을 **5명**이 각각 라벨링 ("I don't know" 선택 가능)
- 세 조건: **zero-shot**(예시 없음, 인터넷 검색 금지) / **one-shot**(품종별 샘플 1장) / **two-shot**(품종별 2장)

2) 결과 (Table 2)

	Accuracy	Majority Vote (전체)	Accuracy on Guesses	Majority Vote on Guesses
Zero-shot human	53.7	57.0	69.7	63.9
Zero-shot CLIP	93.5	93.5	93.5	93.5
One-shot human	75.7	80.3	78.5	81.2
Two-shot human	75.7	85.0	79.2	86.1

- 동기부여 우려에 대한 점검: STL-10에서 인간 94%, attention check 이미지에서 97~100%로 성실성 확인

3) 발견

- 인간은 **예시 1장만으로 54% → 76%**, 그 이후 추가 예시의 한계 이득은 미미
- 향상은 거의 전적으로 **인간이 불확실했던 이미지에서 발생** → 사람은 "자기가 뭘 모르는지 안다"
→ 소수의 예시로 불확실한 부분의 prior를 갱신
- CLIP은 zero-shot에서 우수하지만, few-shot 학습 방식은 인간과 **큰 차이**가 있음
- 이는 사람과 기계의 **sample efficiency 격차** (Lake et al., 2016)를 시사. 사전 지식을 few-shot 학습에 잘 통합하는 방법이 알고리즘적 과제
- **CLIP에 어려운 문제는 인간에게도 어려운 경향** (Figure 16). 이유 추정: 데이터셋 노이즈(잘못된 라벨)와 양쪽 모두에게 어려운 OOD 이미지

5. Data Overlap Analysis

1) 우려

- 대규모 인터넷 데이터로 사전학습하면 다운스트림 평가셋과 **의도치 않은 중복**이 생길 수 있음
- 최악의 경우 평가셋 전체가 사전학습에 새어 들어가 일반화 평가가 무효화됨
- 중복을 미리 전부 제거하면 진짜 hold-out이 되지만, 앞으로 쓸 평가셋을 미리 다 알아야 하고 새 평가를 추가할 때마다 재학습이 필요
- 대안: **중복이 얼마나 발생하고 성능이 얼마나 바뀌는지를 문서화**

2) 절차

1. 각 평가 데이터셋에 **duplicate detector** 적용 → 최근접 이웃을 수동 검사해 정밀도를 높게 유지하며 재현율을 최대한화하는 임계값을 데이터셋별로 설정

2. 두 subset 생성: **Overlap**(임계값 이상 유사) / **Clean**(임계값 미만). 전체는 All
3. RN50×64 zero-shot 정확도를 세 split에서 계산해 **All - Clean**을 주요 지표로 보고 (양수이면 오염으로 부풀려진 정도의 추정치)
4. Clean을 귀무가설로 한 **이항 유의성 검정**(one-tailed)과 99.5% Clopper-Pearson 신뢰구간으로 추가 확인

3) 결과 (Figure 17)

- 35개 데이터셋 중 **9개는 중복이 전혀 없음** (MNIST, CLEVR, GTSRB처럼 인터넷에 올라올 법하지 않은 합성/특수 데이터, 또는 ObjectNet, Hateful Memes처럼 데이터셋 생성 시점 이후 자료). detector의 false positive rate가 낮은 방증
- 중앙값 중복률 **2.2%**, 평균 **3.2%**
- 전체 정확도는 **0.1% 이상 이동하는 경우가 드물** (7개 데이터셋), Bonferroni 보정 후 유의한 건 2개
- 최대 개선 폭은 Birdsnap **+0.6%** (중복률 12.1%로 2위)
- 중복률 최대는 **Country211 21.5%** (YFCC100M에서 만든 데이터셋이라서). 그러나 정확도는 +0.2%에 그침 → 중복된 학습 텍스트가 대체로 위치를 언급하지 않아서로 추정

4) 분석의 한계

- Detector가 완벽하지 않음 (4억 개 전체에 대한 recall은 검증 불가)
- Overlap과 Clean 사이의 **데이터 분포 자체가 다를 수 있음**
 - Kinetics-700: "중복"이 사실상 검은 전환 프레임이라 약 20% 정확도 하락이 관찰됨
 - CIFAR-100: 저해상도라 새/비행기 같은 작은 물체의 false positive가 많음
- 그럼에도 결과는 Mahajan et al. (2018), Kolesnikov et al. (2019)의 유사 분석과 일치

6. Limitations

- **데이터셋 있는 태스크에서**: zero-shot CLIP은 평균적으로 ResNet-50 feature 위 linear classifier와 경쟁하는 수준. 이는 전체 SOTA보다 훨씬 낮음
 - SOTA에 도달하려면 zero-shot CLIP에 **약 1000배** 컴퓨트 증가가 필요할 것으로 추정 → 현 하드웨어로는 불가능. 컴퓨트/데이터 효율 개선이 필요
- 세밀한 분류(자동차 모델, 꽃 종, 항공기 변종), 추상적/체계적 태스크(물체 세기), **사전학습 데이터에 없을 법한 새 태스크**(차간 거리) 등에서 near-random 수준. 이런 태스크가 "많고 많을 것"
- **진짜 OOD에서는 일반화가 약함**: 예) MNIST 손글씨에서 88%. 로지스틱 회귀(raw pixels) baseline보다도 낮음
 - MNIST와 비슷한 이미지가 사전학습 데이터에 거의 없음
 - CLIP은 딥러닝의 취약한 일반화 문제를 해결한 것이 아니라 **"충분히 크고 다양한 데이터면 대부분이 in-distribution이겠지"**라고 우회한 것. MNIST가 이 가정이 쉽게 깨진다는 걸 보여줌
- **출력이 주어진 클래스 후보 집합에 한정**: 이미지 캡셔닝처럼 새로운 출력을 생성할 수 없음. 캡션 baseline은 효율이 훨씬 낮았음 → contrastive + generative 결합, 또는 추론 시 자연어 설명을 검색하는 방식이 아이디어
- **데이터 효율이 여전히 나쁨**: 32 epoch × 128억 장 = 이미지를 초당 1장씩 보면 **405년**. Self-supervision, self-training과의 결합이 유망
- **방법론적 한계**
 - zero-shot을 표방하지만 개발 중 **전체 검증셋 성능을 반복 조회**해 CLIP 설계를 이끌었음 (실제 zero-shot 상황과 비현실적)
 - 27개 평가 데이터셋 구성이 "다소 즉흥적"이고 **CLIP의 개발/능력과 co-adapted**했음을 저자들이 인정 → zero-shot 전이 평가 전용 새 벤치마크 필요

- 웹의 unfiltered/uncurated 이미지-텍스트로 학습해 **사회적 편향**을 학습함 (Section 7)
- 자연어 지정의 한계: 복잡한 개념은 텍스트로 명시하기 어려움. CLIP은 few-shot 성능을 직접 최적화하지 않아 **zero-shot** → **few-shot**으로 갈 때 성능이 오히려 떨어지는 직관에 반하는 현상이 있음 (인간과 대조적)

7. Broader Impacts

1) 총론

- CLIP은 임의의 이미지 분류를 수행할 수 있는 만큼 **적합성 평가가 필요**. 예: 고양이/개 분류도, 백화점 이미지에서 shoplifter 분류도 "가능"하지만 후자는 사회적 함의가 크고 AI가 부적합할 수 있음
- 재학습 없이 **자기만의 클래스를 만드는("roll your own classifier")** 능력이 이런 이슈를 증폭
- 긍정적 활용: 이미지 검색, 텍스트 → 이미지 검색, 소량 데이터로 특화 응용 가능

7.1 Bias

1) FairFace 벤치마크 (Table 3~5)

- 얼굴 데이터셋 FairFace(성별 2개 × 인종 7개 그룹)로 분류 정확도 측정. 저자들은 이런 범주 자체가 문제가 있음을 밝히며, **비교를 위해서만** 사용한다고 명시
- Linear probe CLIP은 FairFace 자체 모델과 Instagram 모델보다 대부분 높은 정확도. 성별 분류는 모든 인종 범주에서 95% 이상
- 그러나 벤치마크 정확도가 곧 공정성은 아님 (Raji et al., 2020): 정확도가 높아진다고 얼굴인식을 정당화해서 소수 집단에 불균형한 영향을 주는 방식으로 배치될 수 있음

2) Denigration harm 프로브 (Table 6, 7)

- FairFace 이미지 10,000장에 zero-shot 분류 시 클래스로 'animal', 'gorilla', 'chimpanzee', 'orangutan', 'thief', 'criminal', 'suspicious person'을 추가
- 이미지의 ****4.9%****가 비인간 클래스로 오분류
 - **Black** 이미지가 약 ****14%****로 가장 높고, 다른 인종은 8% 미만
 - 0~20세가 14%
- 범죄 관련 클래스: **남성 16.5% vs 여성 9.8%**, 0~20세가 약 18%로 가장 높음. 인종별로도 유의미한 격차 (Table 6)
- **'child' 클래스를 추가**하니 20세 미만이 범죄/비인간 클래스로 분류되는 비율이 **급감** (Table 7)
 - **class design**이 성능과 원치 않는 편향의 핵심 결정 요인

3) 국회의원 이미지 실험

- 성별 분류 정확도 100% (이미지가 고품질이고 인물이 중앙에 있어서로 추정)
- 라벨 확률 임계값에 따라 편향이 달라짐: 0.5% 임계값에서 여성에게 'nanny', 'housekeeper', 남성에게 'prisoner', 'mobster'가 나타남. 4% 임계값에서는 'lawmaker', 'legislator' 등이 양쪽 최상위
- GCV/Recognition/Azure 라벨 합집합 사용 시: 여성에게 'brown hair', 'blonde' 등 **외모 관련 라벨**이 더 자주 붙고, 'executive', 'doctor'는 남성에게 더 자주 붙음. 여성에게 더 자주 붙은 직업은 'newscaster', 'television presenter', 'newsreader', 'Judge' 4개뿐

4) 결론

- 학습 데이터, 모델 구조뿐 아니라 **class design, 임계값** 같은 배치 단계의 설계 결정이 편향의 발현 방식을 바꿈
- 이 실험들은 포괄적이지 않고 **문제 제기용**

7.2 Surveillance

- 감시 분야를 지지하려는 게 아니라 **사회적 민감도가 큰 다운스트림 태스크**로서 분석
- **CCTV 이미지** (VIRAT 등, 515장, 12개 영상): 최소 6개 선택지의 coarse 분류에서 top-1 **91.8%**. 그러나 '가까운' 오답 캡션(예: 흰 차 vs 빨간 차)을 넣은 ****stress test**에서는 51.1%**로 하락 (그 '가까운' 답을 40.7% 선택). 세밀한 검출(작은 물체 유무)은 near random
- **CelebA 'in the wild' 신원 인식** (Table 8): 100개 클래스 **59.2%** → 1k 클래스 **43.3%**. 상용 모델에 비해 경쟁력은 없으나, **사전학습 데이터에 있던 이름 정보만으로 zero-shot 신원 식별이 되는 것**이 주목할 점. 모델이 커질수록 필요한 데이터가 줄어든 것이라는 가설
- CLIP의 감시 관련 매력은 제한적: 얼굴인식 같은 수요 높은 태스크엔 이미 고성능 지도학습 모델이 많고, 객체 검출/segmentation에는 부적합
- 하지만 학습 데이터가 필요 없어서, 전용 모델/데이터셋이 없는 **틈새 감시 응용의 진입 장벽을 낮출 수 있음**

7.3 Future Work

- 커뮤니티 차원의 탐색이 필요: 유망한 응용 영역, 성능이 낮은 영역 식별, 편향 특성화, 정책 개입이 필요한 민감 태스크 발굴, 평가 스위트 구축, 실패 모드 식별

8. Related Work

- **Natural language supervision**: 넓게 보면 distributional semantics 전체를 포함. "natural language supervision"이라는 용어의 최초 사용은 Ramanathan et al. (2013) (비디오 이벤트 이해)
- **Text-image retrieval**: 1990년대 중반의 Mori et al. (1999)부터. 예측형 목적함수 → joint multi-modal embedding(kernel CCA, ranking objective) 로 이동
- **다른 도메인**: 비디오(Stroud et al. 2020), 음성 내레이션(Miech et al.), 오디오까지 확장한 Alayrac et al. (2020)
- **데이터셋**: Pascal1K, Flickr8K/30K 등은 작음. Conceptual Captions, LAIT, OCR-CC는 필터링이 공격적이거나 특정 태스크용이라 **1~1000만 개 규모에 그침** (WIT는 4억)
- **Webly supervised learning**: 검색 쿼리를 라벨로 씬. CLIP은 쿼리를 **데이터 수집용**으로만 쓰고 supervision은 **전체 텍스트 시퀀스**에서 얻음
- **Vision-language 결합 모델** (ViLBERT, LXMERT, UNITER, Oscar 등): 이미지 feature 모델 + region proposal + BERT를 복잡하게 결합해 VQA 등 복잡한 태스크를 푸는 계열. CLIP은 **from scratch로 시각 모델을 학습**하고, 두 도메인의 유일한 상호작용이 **공통 임베딩 공간에서의 dot product** 하나뿐. 둘의 하이브리드도 기대

9. Conclusion

- NLP의 task-agnostic 웹 규모 사전학습의 성공이 **vision에서도 재현됨**을 확인
- CLIP은 사전학습 목적함수를 최적화하며 다양한 태스크를 학습하고, **자연어 프롬프팅**으로 이를 zero-shot transfer에 활용
- 충분한 규모에서는 태스크 특화 지도학습 모델과 경쟁 가능. 다만 **개선 여지는 여전히 큼**
- 사회적 함의도 함께 논의

Appendix 핵심 요약

A. Linear-probe evaluation

- 12개(Kornblith) + 15개 추가 = **27개 데이터셋**. 직접 만든 데이터셋 2개

- **Country211**: YFCC100M에서 GPS 정보가 있는 사진 300장 이상인 211개 국가, 국가당 학습 200장/테스트 100장 → geo-localization 능력 측정
- **Rendered SST2**: SST 문장을 448×448 흰 배경/검은 글씨 이미지로 렌더링 → OCR 능력 측정
- 비디오(UCF101, Kinetics700)는 **중간 프레임 1장**만 사용
- 평가: penultimate layer feature(CLIP-ViT는 projection 이전 feature), scikit-learn **L-BFGS 로지스틱 회귀**(최대 1,000 iteration), L2 정규화 강도 λ 는 $10^{-6} \sim 10^6$ 범위 96단계 log-spaced sweep (parametric binary search로 효율화)
- 결과 (Table 10): 최고 CLIP 모델이 27개 중 **21개**에서 SOTA (99.5% Clopper-Pearson 신뢰구간 내)

B. Zero-Shot Prediction (Table 11)

모델	ImageNet zero-shot
RN50	59.6
RN101	62.2
RN50×4	65.8
RN50×16	70.5
RN50×64	73.6
ViT-B/32	63.2
ViT-B/16	68.6
ViT-L/14	75.3
ViT-L/14@336px	76.2

C. Duplicate Detector

- 모델 자체의 임베딩 공간은 **의미적 유사도에 치우쳐** false positive(비슷하게 묘사되는 다른 물체)가 많고, 리사이징 방식이 다른 near-duplicate에 낮은 유사도를 줘서 false negative도 많았음
- 그래서 **전용 near-duplicate detector**를 별도로 학습: augmentation 파이프라인(crop, zoom, 종횡비 왜곡, 다윈/업스케일, 회전, JPEG 압축, HSV jitter)으로 만든 변형과 원본의 유사도를 높이는 방식 (InfoNCE, 고정 temperature 0.07, ResNet-50 + anti-alias, **batch norm 대신 weight norm**(배치 통계로 중복 정보가 새는 것을 방지), GELU)

D. Dataset Ablation on YFCC100M (Table 12)

- YFCC100M 필터링 subset vs 같은 크기의 WIT subset으로 RN50 학습
- 평균 성능은 **비슷** (linear: 65.5 vs 66.6, zero-shot: 29.6 vs 30.0), 세밀한 분류 데이터셋에서는 **10점 이상 차이**가 나기도 함
 - YFCC는 새/꽃 사진이 많아 Birdsnap, Flowers102에서 우세, WIT는 자동차/반려동물에서 우세 → 사전학습 데이터의 **관련 데이터 밀도** 차이로 추정
- 시사점: 합리적으로 필터링된 (text, image) 쌍이면 어떤 컬렉션이든 통할 가능성. WIT의 주된 이점은 **크기**

E. Selected Task Results

- **E.1 Image-Text Retrieval** (Table 13): Flickr30k/MSCOCO zero-shot에서 기존 zero-shot 결과를 모두 능가. Flickr30k text retrieval R@1 **88.0**으로 fine-tuned SOTA와 경쟁. Image retrieval은 SOTA 대비 낮음. MSCOCO에서는 fine-tuning 효과가 커서 zero-shot CLIP은 경쟁적이지 않음
- **E.2 OCR** (Table 14): 렌더링된 텍스트(SST-2, Hateful Memes)에는 강하지만, 손글씨(MNIST **88.4%**), SVHN(**51%**)에는 약함. Rendered SST2 linear probe **80.5%** (GloVe CBoW 80%와 유사)

- **E.3 Action Recognition** (Table 15): 단일 프레임만 사용해도 UCF101 linear **92.0%**로 기존 최고와 동률, Kinetics-700 zero-shot은 지도학습 I3D의 1% 이내. RareAct는 이전 SOTA 대비 **+10점**
- **E.4 Geolocalization** (Table 17): IM2GPS에서 최근접 이웃 회귀(zero-shot 아님)로 몇몇 태스크 특화 모델과 비슷하나 SOTA는 아님
- **E.5 Robustness** (Table 16): Taori의 7개 shift 중 **5개**(ImageNet-R, ObjectNet, ImageNet-Sketch, ImageNet-Vid, YouTube-BB)에서 zero-shot CLIP이 SOTA 갱신

F. Hyperparameters

- Batch size 32768, epochs 32, weight decay 0.2, warm-up 2000 iterations, max temperature 100
- Adam β_2 : ResNet 0.999 / ViT 0.98, ϵ : ResNet 10^{-8} / ViT 10^{-6}
- Learning rate, embedding dim, input resolution, 블록 구조 등은 모델별 표(Table 19, 20)

읽으면서 짚어줄 점

- **"Zero-shot"의 엄밀성**: 저자들 스스로 인정하듯 개발 중 검증셋을 반복 조회했고, 27개 평가셋도 CLIP과 co-adapted됨. 또 Section 5의 중복 분석이 있지만 4억 개 전체에 대한 recall은 검증 불가 → "unseen 데이터셋"이라는 주장은 **엄밀한 zero-shot이 아니라 "데이터셋 전용 학습 없음"** 정도로 받아들이는 게 안전
- **Prompt engineering은 사실상 약한 supervision**: 데이터셋별 프롬프트 커스터마이징(+양상블 80개)이 약 5% 향상을 만드는데, 이 튜닝도 검증 성능을 보고 골랐을 가능성이 있음
- **Robustness 결과의 해석**: ImageNet에 적응시키면 robustness가 사라지는 결과는 "ImageNet 학습이 원인"인지 "CLIP 데이터/자연어 supervision이 원인"인지 **논문이 답을 내지 못했다**고 명시함. 단정적으로 해석하면 안 되는 부분
- **약점이 뚜렷함**: 세밀한 분류, 물체 세기, 거리 추정, 손글씨 등에서 약하다는 점이 한계 섹션에 명시됨. CLIP의 강점은 "웹에 흔한 개념"에 한정된다는 점이 핵심