

DeepSeek

📅 date	2026년 9월 3일
# Num	10
🔗 논문 원문 링크	https://arxiv.org/pdf/2501.12948
≡ 유형	BOAZ 학기 1주차 (2)

DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning

DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning

1. Abstract
2. Introduction
3. DeepSeek-R1-Zero 상세
 - GRPO (Group Relative Policy Optimization)
 - 보상 설계 (Reward Design)
 - 결과
4. DeepSeek-R1 — 멀티스테이지 파이프라인
 - Reward Model 학습 (일반 데이터용)
5. Experiments (결과 요약)
6. Discussion — 한계점
7. Conclusion
8. 두 논문 차별점 비교
9. GPT / DeepSeek 수식 정리

1. Abstract

사람이 만든 reasoning 데모 없이 **순수 RL만으로** LLM의 추론 능력(수학, 코딩경진, STEM)을 이끌어냄. self-reflection·verification·전략 재탐색 같은 고급 추론 패턴이 자연발생(emergent). 대형 모델의 추론 패턴을 소형 모델로 distillation 가능.

2. Introduction

- 기존 CoT(few-shot 예시, "Let's think step by step")와 post-training 방식은 **사람이 만든 reasoning trace에 의존**
→ (1) 확장성 제약, (2) 사람의 인지적 편향 주입, (3) 사람이 제공한 예시 수준을 넘는 우월한 추론 경로 탐색이 원천 차단
- 접근: **DeepSeek-V3-Base 위에 SFT 없이 바로 GRPO(RL) 적용**. 보상은 오직 "최종 답의 정확성"만 사용, 추론 과정 자체엔 제약을 두지 않음
- 결과물: R1-Zero(순수 RL) → 가독성/언어혼용 문제 있음 → R1(멀티스테이지: rejection sampling + RL + SFT 결합)

3. DeepSeek-R1-Zero 상세

GRPO (Group Relative Policy Optimization)

PPO의 경량화 버전. **Value model을 제거**하고 그룹 내 상대 보상으로 advantage 추정.

$$J_{GRPO}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \min \left(\frac{\pi_{\theta}(o_i|q)}{\pi_{\theta_{old}}(o_i|q)} A_i, \text{clip} \left(\frac{\pi_{\theta}(o_i|q)}{\pi_{\theta_{old}}(o_i|q)}, 1 - \epsilon, 1 + \epsilon \right) A_i \right) - \beta D_{KL}(\pi_{\theta} | \pi_{ref}) \right]$$

- 질문 q당 그룹 $\{o_1, \dots, o_G\}$ 샘플링 → 그룹 내 상대적 우열로 advantage 계산 (PPO처럼 GAE·value model 불필요)
- KL divergence를 loss에 직접 추가**(unbiased estimator), PPO는 per-token 보상에 KL penalty를 얹는 방식 — 이 차이가 response length에 미치는 영향이 다름(PPO는 길이를 암묵적으로 억제하는 경향)

- 학습 세팅: lr 3e-6, KL계수 0.001, temperature 1, 질문당 16개 출력 샘플링(초기 max 32,768토큰 → 8.2k step 이후 65,536토큰), 배치 512(32질문×16출력), 400 step마다 reference model 갱신, 총 10,400 step(≈1.6 epoch)

보상 설계 (Reward Design)

$$Reward_{rule} = Reward_{acc} + Reward_{format}$$

- **Accuracy reward:** 수학은 정해진 형식(박스 등) 안 최종 답 매칭, 코드는 컴파일러+테스트케이스로 검증
- **Format reward:** `<think>...</think>` 태그 준수 여부
- **의도적으로 neural reward model을 배제** — 대규모 RL에서 reward hacking에 취약하고, 재학습 비용도 크기 때문 (Discussion에서 실제로 이 문제 재확인, Figure 6)

결과

- AIME 2024 pass@1: **15.6% → 77.9%** (RL만으로), self-consistency(cons@16) 적용 시 **86.7%** — 인간 참가자 평균을 상회
- 응답 길이가 학습 진행에 따라 자연스럽게 증가(Figure 1b) → "더 오래 생각하는 법"을 스스로 학습
- **"Aha moment" (Table 2):** 모델이 풀이 도중 "Wait, wait. Wait. That's an aha moment I can flag here"라며 스스로 재검토 — reflective word("wait" 등) 빈도가 학습 후반(8000 step 이후)에 급증(Figure 9b)
- 한계: 가독성 낮음, 영어/중국어 혼용, reasoning 외 영역(글쓰기, 개방형 QA)에서 성능 제한적

4. DeepSeek-R1 — 멀티스테이지 파이프라인




Figure 2 | The multi-stage pipeline of DeepSeek-R1. A detailed background on DeepSeek-V3 Base and DeepSeek-V3 is provided in Supplementary A.1. The models DeepSeek-R1 Dev1, Dev2, and Dev3 represent intermediate checkpoints within this pipeline.




Figure 3 | Demonstration of PPO and our GRPO. GRPO foregoes the value model, instead estimating the advantages from group scores.

1. **Cold Start:** 수천 개의 long-CoT 데이터셋을 사람이 다듬어 SFT (인칭 서술, 언어 일관성 확보가 목적 — R1-Zero는 "we"를 쓰거나 인칭 자체가 없는데 R1은 "I"를 사용하도록 유도). sympy로 수학 정답 파싱, 반복/언어혼용 필터링 후 DeepSeek-V3로 최종 다듬기
2. **RL 1단계:** reasoning 태스크 + **language consistency reward** 추가

$$Reward_{language} = \frac{Num(Words_{target})}{Num(Words)}$$
 (CoT 내 목표 언어 단어 비율) — ablation에서 성능은 소폭 하락하지만 가독성 향상 확인 (Appendix B.6, Figure 7)
3. **Rejection Sampling + SFT (800K 샘플):** 1단계 RL 체크포인트에서 다수 샘플링 후 정답만 필터링해 **60만 개 reasoning** 데이터 + DeepSeek-V3 SFT 파이프라인 재사용한 **20만 개 non-reasoning**(글쓰기, 사실QA, 자기인식, 번역, SW엔지니어링) 데이터 결합
4. **RL 2단계:** reasoning은 rule-based reward, general 데이터는 helpful/safety reward model 사용

$$Reward = Reward_{reasoning} + Reward_{general} + Reward_{language}$$
 temperature 0.7로 낮춤(높으면 생성 불안정), 1,700 step 중 마지막 400 step에만 general instruction data 포함(너무 오래 학습하면 reward hacking 위험)

Reward Model 학습 (일반 데이터용)

- **Helpful RM:** arena-hard 프롬프트 형식으로 preference pair 생성, 같은 쌍을 4번 평가해 평균 낸 뒤 점수차 $\Delta > 1$ 인 것만 채택, 총 6.6만 쌍, 길이 편향 제거 위해 응답 길이 맞춤
- **Safety RM:** 10.6만 개 프롬프트에 "안전/불안전" 라벨, pairwise가 아닌 pointwise 학습

5. Experiments (결과 요약)




Figure 1 | (a) AIME accuracy of DeepSeek-R1-Zero during training. AIME takes a mathematical problem as input and a number as output, illustrated in Table 32. Pass@1 and Cons@16 are described in Supplementary D.1. The baseline is the average score achieved by human participants in the AIME competition. (b) The average response length of DeepSeek-R1-Zero on the training set during the RL process. DeepSeek-R1-Zero naturally learns to solve reasoning tasks with more thinking time. Note that a training step refers to a single policy update operation.

Table 3 | Experimental results at each stage of DeepSeek-R1. Numbers in bold denote the performance is statistically significant (t-test with $p < 0.01$).

	Benchmark (Metric)	R1-Zero	R1-Dev1	R1-Dev2	R1-Dev3	R1
English	MMLU (EM)	88.8	89.1	91.2	91.0	90.8
	MMLU-Redux (EM)	85.6	90.0	93.0	93.1	92.9
	MMLU-Pro (EM)	68.9	74.1	83.8	83.1	84.0
	DROP (3-shot F1)	89.1	89.8	91.1	88.7	92.2
	IF-Eval (Prompt Strict)	46.6	71.7	72.0	78.1	83.3
	GPQA Diamond (Pass@1)	75.8	66.1	70.7	71.2	71.5
	SimpleQA (Correct)	30.3	17.8	28.2	24.9	30.1
	FRAMES (Acc.)	82.3	78.5	81.8	81.9	82.5
	AlpacaEval2.0 (LC-winsrate)	24.7	50.1	55.8	62.1	87.6
	ArenaHard (GPT-4-110k)	53.6	77.0	73.2	75.6	92.3
Code	LiveCodeBench (Pass@1-COT)	50.0	57.5	63.5	64.6	65.9
	Codeforces (Vercel)	80.4	84.5	90.5	92.1	96.3
	Codeforces (Rating)	1444	1534	1687	1746	2029
	SWE Verified (Resolved)	43.2	39.6	44.6	45.6	49.2
	Aider-Polyglot (Acc.)	12.2	6.7	25.6	44.8	53.3
Math	AIME 2024 (Pass@1)	77.9	59.0	74.0	78.1	79.8
	MATH-500 (Pass@1)	95.9	94.2	95.9	95.4	97.3
	CNMO 2024 (Pass@1)	88.1	58.0	73.9	77.3	78.8
Chinese	CLUEWSC (EM)	93.1	92.8	92.6	91.6	92.8
	C-Eval (EM)	92.8	85.7	91.9	86.4	91.8
	C-SimpleQA (Correct)	66.4	58.8	64.2	66.9	63.7

벤치마크	R1-Zero	R1-Dev1	R1-Dev2	R1-Dev3	R1	비고
AIME 2024	77.9	59.0	74.0	78.1	79.8	Dev1은 cold-start 데이터가 적어 오히려 하락
MATH-500	95.9	94.2	95.9	95.4	97.3	
Codeforces(백분위)	80.4	84.5	90.5	92.1	96.3	
AlpacaEval2.0	24.7	50.1	55.8	62.1	87.6	최종 RL 단계에서 크게 향상(일반 지시 따르기)
IF-Eval	46.6	71.7	72.0	78.1	83.3	

- Dev1 → Dev2: reasoning-oriented RL이 코드/수학/STEM 크게 향상, 범용 벤치마크는 소폭
- Dev2 → Dev3: non-reasoning SFT 데이터 추가로 AlpacaEval/Aider-Polyglot 향상
- 최종 R1: 일반 지시따르기·선호 벤치마크에서 주 향상 (AlpacaEval +25%, ArenaHard +17%)
- 타 모델 비교(Table 8): Claude-3.5-Sonnet, GPT-4o, o1-mini, o1-1217과 비교해 수학/코딩에서 o1-1217과 대등하거나 근접, MMLU 90.8

Table 7 | Training costs of DeepSeek-R1, assuming the rental price of H800 is \$2 per GPU hour.

Training Costs	DeepSeek-R1-Zero	SFT data creation	DeepSeek-R1	Total
in H800 GPU Hours	101K	5K	41K	147K
in USD	\$202K	\$10K	\$82K	\$294K

Table 8 | Comparison between DeepSeek-R1 and other representative models. Numbers in bold denote the performance is statistically significant (t-test with $p < 0.01$).

Benchmark (Metric)	Claude-3.5-Sonnet-1022	GPT-4o-0513	DeepSeek-V3	OpenAI-o1-mini	OpenAI-o1-1217	DeepSeek-R1
Architecture	-	-	MoE	-	-	MoE
# Activated Params	-	-	37B	-	-	37B
# Total Params	-	-	671B	-	-	671B
English	MMLU (EM)	88.3	87.2	88.5	85.2	91.8
	MMLU-Redux (EM)	88.9	88.0	89.1	86.7	92.9
	MMLU-Pro (EM)	78.0	72.6	75.9	80.3	84.0
	DROP (3-shot F1)	88.3	83.7	91.6	83.9	90.2
	IF-Eval (Prompt Strict)	86.5	84.3	86.1	84.8	-
	GPQA Diamond (Pass@1)	65.0	49.9	59.1	60.0	75.7
	SimpleQA (Correct)	28.4	38.2	24.9	7.0	47.0
	FRAMES (Acc.)	72.5	80.5	73.3	76.9	-
	AlpacaEval2.0 (LC-winrate)	52.0	51.1	70.0	57.8	-
	ArenaHard (GPT-4-1106)	85.2	80.4	85.5	92.0	-
Code	LiveCodeBench (Pass@1-COT)	38.9	32.9	36.2	53.8	63.4
	Codeforces (Percentile)	20.3	23.6	58.7	93.4	96.6
	Codeforces (Rating)	717	759	1134	1820	2061
	SWE Verified (Resolved)	50.8	38.8	42.0	41.6	48.9
	Aider-Polyglot (Acc.)	45.3	16.0	49.6	32.9	61.7
Math	AIME 2024 (Pass@1)	16.0	9.3	39.2	63.6	79.2
	MATH-500 (Pass@1)	78.3	74.6	90.2	90.0	96.4
	CNMO 2024 (Pass@1)	13.1	10.8	43.2	67.6	-
Chinese	CLUEWSC (EM)	85.4	87.9	90.9	89.9	-
	C-Eval (EM)	76.7	76.0	86.5	68.9	-
	C-SimpleQA (Correct)	55.4	58.7	68.0	40.3	-

6. Discussion — 한계점

1. 구조화 출력/툴 사용 미흡: 검색엔진·계산기 등 외부 도구 활용 불가
2. 토큰 효율: 쉬운 문제에 과도하게 긴 추론 (overthinking) — 난이도에 따라 동적 배분은 하지만 최적화 여지 있음
3. 언어 혼용: 중국어/영어 외 언어 질의 시에도 영어로 추론하는 경향 (V3-Base가 주로 중/영 데이터로 학습됐기 때문)
4. 프롬프트 민감성: few-shot이 오히려 성능 저하 → zero-shot 권장
5. SW엔지니어링: 평가 시간이 길어 RL 데이터가 적음 → V3 대비 개선 제한적
6. **Reward Hacking**: neural reward model 사용 시 정책이 리워드의 허점을 파고들어 실제 성능(CodeForces)은 떨어지는데 reward score는 오르는 현상 실측 (Figure 6)




Figure 6 | Reward hacking: the reward exhibits an increasing trend as the performance on CodeForces decreases for training.

Table 2 | An interesting “aha moment” of an intermediate version of DeepSeek-R1-Zero. The model learns to rethink using an anthropomorphic tone. This is also an aha moment for us, allowing us to witness the power and beauty of reinforcement learning.

Question: If $a > 1$, then the sum of the real solutions of $\sqrt{a - \sqrt{a + x}} = x$ is equal to

Response: <think>

To solve the equation $\sqrt{a - \sqrt{a + x}} = x$, let's start by squaring both ...

$$(\sqrt{a - \sqrt{a + x}})^2 = x^2 \implies a - \sqrt{a + x} = x^2.$$

Rearrange to isolate the inner square root term:

$$(a - x^2)^2 = a + x \implies a^2 - 2ax^2 + (x^2)^2 = a + x \implies x^4 - 2ax^2 - x + (a^2 - a) = 0$$

...

Wait, wait. Wait. That's an aha moment I can flag here.

Let's reevaluate this step-by-step to identify if the correct sum can be ...

We started with the equation:

$$\sqrt{a - \sqrt{a + x}} = x$$

First, let's square both sides:

$$a - \sqrt{a + x} = x^2 \implies \sqrt{a + x} = a - x^2$$

Next, I could square both sides again, treating the equation: ...

...




Figure 9 | Evolution of reasoning behaviors during training. (a) Frequency of representative reflective words during the training process; (b) Specific occurrence patterns of the word “wait” throughout the training process.

7. Conclusion

사전학습된 체크포인트는 이미 복잡한 추론에 대한 잠재력을 갖고 있고, 이를 끌어내는 핵심은 대규모 사람 주석이 아니라 **"어려운 문제 + 신뢰 가능한 검증자 + 충분한 RL 컴퓨팅"**. Self-verification, reflection 같은 정교한 행동은 명시적으로 가르치지 않아도 RL 과정에서 유기적으로 발현.

8. 두 논문 차별점 비교

	GPT-1	DeepSeek-R1
핵심 인사이트	비지도 LM 사전학습이 태스크 지식을 암묵적으로 담는다	결과 기반 RL만으로 고급 추론 패턴이 발현된다
SFT의 위치	파인튜닝(=SFT)이 핵심 전이 메커니즘	SFT는 오히려 탐색을 제한할 수 있다는 가설, R1-Zero는 SFT 생략
아키텍처 혁신	Decoder-only Transformer + 입력 변환	GRPO(value model 제거) + reward 설계
비용 절감 포인트	태스크별 아키텍처 대신 입력 변환만 바꿈	Value model 제거로 메모리/연산 절감

9. GPT / DeepSeek 수식 정리

- GPT-1: $L_3 = L_2 + \lambda L_1$ (지도학습 + 보조 LM), $\lambda = 0.5$
- DeepSeek-R1: $A_i = \frac{r_i - \text{mean}(r)}{\text{std}(r)}$ (그룹 상대 advantage)
 $Reward = Reward_{reasoning} + Reward_{general} + Reward_{language}$