

Diffusion

📅 date	2026년 9월 17일
🔗 논문 원문 링크	https://arxiv.org/pdf/2006.11239
≡ 유형	BOAZ 학기 3주차 (2)

Denoising Diffusion Probabilistic Models (DDPM)

Denoising Diffusion Probabilistic Models (DDPM)

[Background / Abstract](#)

[2. Background](#)

[3. Diffusion Models and Denoising Autoencoders](#)

[4. Experiments](#)

[5. Related Work](#)

[6. Conclusion](#)

Background / Abstract

- Diffusion probabilistic model: 비평형 열역학(nonequilibrium thermodynamics)에서 영감을 받은 latent variable model
- 핵심 기여: 특정 파라미터화가 **denoising score matching**(다중 노이즈 레벨) 및 **annealed Langevin dynamics**와 동치임을 보임
- 성과: CIFAR10 unconditional에서 Inception Score 9.46, FID 3.17(SOTA), 256×256 LSUN에서 ProgressiveGAN과 유사한 품질
- 로그우도는 다른 우도 기반 모델만큼 경쟁력 있진 않지만(대부분의 codelength가 지각 불가능한 디테일 묘사에 소모 됨), 샘플 품질은 뛰어남

2. Background

1) 모델 구조

- $p_\theta(x_0) := \int p_\theta(x_{0:T}), dx_{1:T}$
→ 여기서 $x_1, \dots, x_T$ 는 데이터와 같은 차원의 latent
- Reverse process** (학습 대상): Gaussian transition을 갖는 Markov chain, $p(x_T) = \mathcal{N}(x_T; 0, I)$ 에서 시작

$$p_\theta(x_{0:T}) := p(x_T) \prod_{t=1}^T p_\theta(x_{t-1}|x_t), \quad p_\theta(x_{t-1}|x_t) := \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

- Forward(diffusion) process** (고정, 파라미터 없음): variance schedule $\beta_1, \dots, \beta_T$ 에 따라 점진적으로 Gaussian noise 추가

$$q(x_{1:T}|x_0) := \prod_{t=1}^T q(x_t|x_{t-1}), \quad q(x_t|x_{t-1}) := \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I)$$

2) 학습 목적함수

- negative log-likelihood의 variational bound를 최적화

$$\mathbb{E}[-\log p_\theta(x_0)] \leq \mathbb{E}_q \left[-\log p(x_T) - \sum_{t \geq 1} \log \frac{p_\theta(x_{t-1}|x_t)}{q(x_t|x_{t-1})} \right] =: L$$

3) 핵심 성질: 임의 시점 x_t 를 closed-form으로 샘플링 가능

- $\alpha_t := 1 - \beta_t$, $\bar{\alpha}_t := \prod_{s=1}^t \alpha_s$ 로 정의하면

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)$$

→ 매 스텝을 순차적으로 거치지 않고도 임의의 t 에서의 노이즈 깬 샘플을 즉시 구할 수 있어 학습 효율이 큼

4) 분산 축소를 위한 재구성 (Eq. 5)

$$L = \mathbb{E}_q \left[\underbrace{D_{KL}(q(x_T|x_0)|p(x_T))}_{L_T} + \sum_{t>1} \underbrace{D_{KL}(q(x_{t-1}|x_t, x_0)|p_\theta(x_{t-1}|x_t))}_{L_t} - \underbrace{1 - \log p_\theta(x_0|x_1)}_{L_0} \right]$$

- x_0 로 조건화된 forward process posterior $q(x_{t-1}|x_t, x_0)$ 는 tractable한 Gaussian이므로, 모든 KL 항을 closed-form으로 계산 가능(고분산 몬테카를로 추정 불필요)

3. Diffusion Models and Denoising Autoencoders

3.1 Forward process와 L_T

- β_t 를 학습 가능한 파라미터가 아니라 상수로 고정 → L_T 는 학습 중 상수이므로 무시 가능

3.2 Reverse process와 $L_{1:T-1}$

- $\Sigma_\theta(x_t, t) = \sigma_t^2 I$ 로 고정(학습 안 함); $\sigma_t^2 = \beta_t$ 또는 $\tilde{\beta}_t$ 둘 다 비슷한 성능
- **핵심 재파라미터화(reparameterization)**: μ_θ 가 forward posterior mean $\tilde{\mu}_t$ 를 직접 예측하는 대신, **노이즈 ϵ 을 예측**하도록 설계

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\alpha_t}} \epsilon_\theta(x_t, t) \right)$$

- 이 파라미터화는 Eq.(12)에서 보듯이 **denoising score matching**(여러 노이즈 스케일에 대해) 목적함수와 닮은 형태로 단순화됨
- 즉, "diffusion model을 variational inference로 학습"하는 것 = "Langevin-like 샘플러를 denoising score matching으로 학습"하는 것과 수학적으로 동치

Algorithm 1 (Training) / Algorithm 2 (Sampling)

- 학습: $x_0 \sim q(x_0), t \sim \text{Uniform}(1, \dots, T), \epsilon \sim \mathcal{N}(0, I)$ 샘플링 후 $|\epsilon - \epsilon_\theta(\sqrt{\alpha_t}x_0 + \sqrt{1-\alpha_t}\epsilon, t)|^2$ 에 대해 gradient descent
- 샘플링: $x_T \sim \mathcal{N}(0, I)$ 에서 시작해 $t = T, \dots, 1$ 까지 역방향으로 ϵ_θ 가 예측한 노이즈를 빼가며 점진적으로 디노이징 (Langevin dynamics와 유사)

3.3 Data scaling, decoder, L_0

- 이미지 데이터 $0, \dots, 255$ 를 $[-1, 1]$ 로 선형 스케일링
- 마지막 단계(L_0)는 discretized Gaussian 기반 독립 디코더 사용 → 손실 없는(lossless) codelength로 해석 가능하게 함

3.4 단순화된 학습 목적함수 (Eq. 14, 가장 중요한 실용적 기여)

$$L_{simple}(\theta) := \mathbb{E}_{t, x_0, \epsilon} [|\epsilon - \epsilon_\theta(\sqrt{\alpha_t}x_0 + \sqrt{1-\alpha_t}\epsilon, t)|^2]$$

- 원래 variational bound의 가중치를 버린 **unweighted 버전** — 작은 t (적은 노이즈)에 대한 손실 항의 가중치를 자연스럽게 낮춤
- 결과적으로 네트워크가 노이즈가 큰(어려운) 디노이징 작업에 더 집중하게 되어 **샘플 품질이 오히려 향상**됨 (단, 로그우도 자체는 true variational bound로 학습할 때가 더 좋음 → rate-distortion trade-off)

4. Experiments

설정

- $T = 1000, \beta_1 = 10^{-4} \rightarrow \beta_T = 0.02$ 로 선형 증가

- 아키텍처: PixelCNN++ 스타일의 U-Net(group normalization), 16×16 해상도에서 self-attention, Transformer 방식의 sinusoidal time embedding으로 시점 t 조건화

결과 (Table 1)

- CIFAR10: Inception Score 9.46, FID 3.17 (당시 조건부 모델들을 포함해도 최상위권)
- L_{simple} 로 학습한 모델이 true variational bound(L)로 학습한 모델보다 **샘플 품질은 우수하나 로그우도(NLL)는 더 나쁨**

Ablation (Table 2)

- $\tilde{\mu}$ 예측 vs ϵ 예측 비교 → ϵ 예측이 L_{simple} 과 결합했을 때 훨씬 우수
- 분산을 학습(learned diagonal Σ)하는 것은 오히려 불안정, 고정 분산이 더 안정적

4.3 Progressive coding & rate-distortion

- variational bound 항 $L_1 + \dots + L_T$ 를 rate, L_0 를 distortion으로 해석
- 대부분의 lossless codelength(절반 이상)가 지각 불가능한 디테일을 설명하는 데 소모됨 → diffusion model이 뛰어난 손실 압축기(lossy compressor)로서의 귀납적 편향(inductive bias)을 가짐을 시사
- Algorithm 3/4: 점진적 손실 압축/복원 절차 제시(개념 증명 수준)

Progressive generation / Connection to autoregressive decoding

- 샘플링 과정 중 예측된 $\hat{x}_0$ 의 변화를 보면, 큰 구조(large-scale feature)가 먼저 나타나고 세부 사항이 나중에 나타남
- 특정 조건 하에서 diffusion model은 좌표를 재배열해 표현할 수 없는 **일반화된 bit ordering**을 갖는 **autoregressive model**로 해석 가능함을 이론적으로 보임

4.4 Interpolation

- 두 소스 이미지를 stochastic encoder q 로 latent에 인코딩 후 선형 보간, reverse process로 다시 디코딩
- diffusion step 수를 늘릴수록 보간이 더 coarse해지고 다양해짐(원본 정보 손실 증가)

5. Related Work

- **vs NCSN(Score-based model)**: 유사한 ϵ -예측 파라미터화를 쓰지만, DDPM은
 - (1) self-attention 포함 U-Net 사용
 - (2) forward process에서 데이터를 스케일링(분산 폭주 방지)
 - (3) x_T 가 거의 순수 노이즈가 되도록 강하게 신호를 파괴
 - (4) 샘플러 계수를 forward process에서 엄밀하게 유도(=variational inference로 명시적으로 학습) — NCSN은 이 계수들을 사후적으로 수작업 설정
- Flow, VAE와 비교: diffusion model은 q 가 파라미터를 갖지 않고, top-level latent x_T 가 데이터와 거의 상호정보량 0이라는 점에서 구별됨

6. Conclusion

- Diffusion model을 이용해 고품질 이미지 샘플을 생성함을 실증
- variational inference(Markov chain 학습), denoising score matching, annealed Langevin dynamics(및 energy-based model), autoregressive model, progressive lossy compression 간의 연결고리를 규명
- 이미지 데이터에 대해 우수한 귀납적 편향을 보이므로, 다른 데이터 양식이나 다른 생성 모델의 구성 요소로서의 활용 가능성을 향후 과제로 제시