

GAN

📅 date	2026년 9월 17일
🔗 논문 원문 링크	https://arxiv.org/pdf/1406.2661
≡ 유형	BOAZ 학기 3주차 (1)

GAN (Generative Adversarial Nets)

GAN (Generative Adversarial Nets)

[Background](#)

[Abstract](#)

[1. Introduction](#)

[2. Related Work](#)

[3. Adversarial Nets \(Method\)](#)

[4. Theoretical Results](#)

[5. Experiments](#)

[6. Advantages and Disadvantages](#)

[7. Conclusion and Future Work](#)

Background

- 기존 딥러닝의 성공은 주로 판별 모델(discriminative model)에 집중 — 고차원 입력을 클래스 레이블로 매핑하는 문제
- 생성 모델(generative model)은 상대적으로 발전이 더뎠음 → maximum likelihood 등에서 등장하는 다루기 힘든 (intractable) 확률 계산 근사의 어려움 때문
- GAN은 이 문제를 완전히 우회하는 새로운 추정 절차를 제안

Abstract

- 두 모델을 동시에 학습하는 적대적(adversarial) 프레임워크 제안
 - **G(Generator)**: 데이터 분포를 포착하는 생성 모델
 - **D(Discriminator)**: 샘플이 진짜 데이터인지 G가 만든 가짜인지 구별하는 판별 모델
- G의 학습 목표: D가 실수하게 만들 확률을 최대화 → 2인 minimax 게임
- 임의의 함수 공간에서는 유일한 해가 존재 → G는 학습 데이터 분포를 완전히 복원하고, D는 모든 곳에서 1/2
- G, D가 MLP(다층 퍼셉트론)이면 backpropagation만으로 전체 시스템 학습 가능, Markov chain이나 근사 추론 네트워크 불필요

1. Introduction

비유 → G는 위조지폐범(counterfeiter), D는 경찰(police)

- G: 진짜처럼 보이는 가짜 화폐를 만들어 적발 없이 사용하려 시도
- D: 위조 화폐를 탐지하려 시도
- 둘의 경쟁이 양쪽 모두를 발전시켜, 결국 위조품이 진품과 구별 불가능한 수준에 도달

이 논문에서 다루는 특수 사례(=adversarial nets)

- G: 랜덤 노이즈를 MLP에 통과시켜 샘플 생성
- D: 역시 MLP
- 학습: backpropagation + dropout만으로 가능, 샘플링은 forward propagation만으로 가능

2. Related Work

접근	특징
RBM, DBM (undirected graphical models)	partition function이 대부분 intractable, MCMC로 근사
DBN (deep belief network)	undirected+directed 혼합, 양쪽의 계산 어려움 모두 가짐
Score matching, NCE	정규화 상수까지 포함해 확률밀도를 explicit하게 명시해야 함
GSN (generative stochastic network)	Markov chain을 정의하는 파라미터화된 기계를 학습

GAN과 NCE의 차이 → NCE는 생성 모델 자체를 판별에 사용(고정된 노이즈 분포 이용), GAN은 별도의 판별 모델을 학습

GAN과 GSN의 차이 → GAN은 샘플링에 Markov chain이 전혀 필요 없음

3. Adversarial Nets (Method)

1) 기본 정의

- 입력 노이즈 변수의 사전 분포 $p_z(z)$ 정의
- $G(z; \theta_g)$: 데이터 공간으로의 매핑을 나타내는 미분 가능한 함수(MLP)
- $D(x; \theta_d)$: 스칼라 하나를 출력 → x 가 p_g 가 아니라 실제 데이터에서 왔을 확률

2) Value function (Eq. 1)

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}} [\log D(x)] + \mathbb{E}_{z \sim p_z} [\log(1 - D(G(z)))]$$

- D는 진짜 예제와 G가 만든 샘플에 올바른 레이블을 부여할 확률을 최대화하도록 학습
- G는 $\log(1 - D(G(z)))$ 를 최소화하도록 동시에 학습

3) 실전 최적화 절차 (Algorithm 1)

- D를 완전 수렴시키는 것은 계산상 비효율적 + 과적합 위험 → k 스텝 D 최적화, 1 스텝 G 최적화를 번갈아 진행
- SML/PCD가 Markov chain을 매 학습 스텝마다 새로 태우지 않고 이어가는 방식과 유사한 전략

4) Non-saturating trick

- 학습 초반엔 G가 형편없어 D가 매우 자신 있게 가짜를 걸러냄 → $\log(1 - D(G(z)))$ 가 saturate(기울기 소실)
- 대신 G가 $\log D(G(z))$ 를 **최대화**하도록 목적함수 변경 → 동일한 fixed point를 가지지만 학습 초반 훨씬 강한 gradient 제공

5) 직관적 설명 (Figure 1)

- (a) 수렴 근처: p_g 가 p_{data} 와 유사, D는 부분적으로만 정확한 분류기
- (b) D가 데이터 샘플을 구별하도록 학습되어 $D^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$ 로 수렴
- (c) G 업데이트 후, $G(z)$ 가 D에 의해 데이터로 분류될 가능성이 높은 방향으로 흐름
- (d) 충분한 용량과 학습 후 $p_g = p_{data}$ 에 도달 → D는 더 이상 구별 불가, $D(x) = 1/2$

4. Theoretical Results

Proposition 1 (최적 판별자)

$$D^*G(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

- $a \log(y) + b \log(1 - y)$ 형태의 함수가 $[0, 1]$ 에서 $\frac{a}{a+b}$ 에서 최댓값을 가진다는 사실로부터 증명

Theorem 1 (전역 최적해)

- $C(G) = \max_D V(G, D)$ 로 재정의하면, $p_g = p_{data}$ 일 때만 전역 최솟값 $C(G) = -\log 4$ 달성
- 증명 핵심: $C(G)$ 가 Jensen-Shannon divergence로 표현됨

$$C(G) = -\log(4) + 2 \cdot \text{JSD}(p_{data}, p_g)$$

- JSD는 항상 0 이상이고 두 분포가 같을 때만 $0 \rightarrow p_g = p_{data}$ 가 유일한 전역 최적해임을 보장

Proposition 2 (알고리즘 수렴)

- D 가 매 스텝 최적점에 도달한다고 가정하면, $U(p_g, D)$ 는 p_g 에 대해 convex
- convex 함수들의 sup의 subderivative 성질을 이용 $\rightarrow$ 충분히 작은 업데이트로 p_g 가 p_{data} 로 수렴함을 보임
- 실제로는 p_g 자체가 아니라 파라미터 θ_g 를 최적화하므로 이론적 보장이 완벽히 성립하진 않지만, 실무에서 MLP의 성능이 이를 뒷받침

5. Experiments

- 데이터셋: MNIST, Toronto Face Database(TFD), CIFAR-10
- G: ReLU + sigmoid 혼합, D: maxout activation, D에 dropout 적용
- 노이즈는 G의 가장 아래층(입력)에만 주입

평가 방법의 한계

- p_g 자체를 explicit하게 평가할 수 없어, 생성된 샘플에 Gaussian Parzen window를 피팅해 test set log-likelihood를 추정
- 고차원에서는 분산이 크고 성능이 좋지 않은 방법이지만, 당시 사용 가능한 최선의 방법

결과 (Table 1)

Model	MNIST	TFD
DBN	138±2	1909±66
Stacked CAE	121±1.6	2110±50
Deep GSN	214±1.1	1890±29
Adversarial nets	225±2	2057±26

- Figure 2: 생성 샘플 시각화(MNIST, TFD, CIFAR-10) — 가장 가까운 학습 데이터도 함께 표시해 단순 암기가 아님을 확인
- Figure 3: latent space z 상에서 선형 보간 $\rightarrow$ 부드럽게 전환되는 이미지 생성 (manifold를 잘 학습했다는 증거)

6. Advantages and Disadvantages

	단점	장점
GAN	$p_g(x)$ 의 명시적 표현 없음, D-G 학습 균형 (synchronization) 필요, G가 너무 많이 학습되면 "Helvetica scenario"(mode collapse 유사 현상)로 다양성 붕괴	Markov chain 불필요, backprop만으로 gradient 획득, 매우 sharp하거나 degenerate한 분포도 표현 가능 (Markov chain 기반 방법은 mixing을 위해 분포가 어느 정도 blurry해야 함)

- Table 2는 directed/undirected graphical models, generative autoencoder, adversarial model 네 가지 패러다임을 Training/Inference/Sampling/Evaluating $p(x)$ /Model design 기준으로 비교

7. Conclusion and Future Work

향후 확장 가능 방향 5가지:

1. **Conditional GAN:** G, D 모두에 조건 c 를 입력으로 추가해 $p(x|c)$ 모델링
2. **Learned approximate inference:** x 가 주어졌을 때 z 를 예측하는 보조 네트워크 학습 (wake-sleep과 유사하나, 생성자 학습 완료 후에도 별도로 학습 가능)
3. 파라미터를 공유하는 조건부 모델들의 family를 학습해 모든 conditional $p(x_S|x_S)$ 를 근사 (MP-DBM의 stochastic 버전)
4. **Semi-supervised learning:** D 또는 inference net의 feature 활용
5. **효율성 개선:** G-D 조정 방법이나 z 샘플링 분포 개선