

Genie

📅 date	2026년 10월 1일
# Num	19
≡ 유형	BOAZ 학기 5주차 (2)

Genie: Generative Interactive Environments

[Background](#)

[World Model vs Video Model](#)

[VQ-VAE와 Discrete Token](#)

[MaskGIT](#)

[ST-Transformer \(Spatiotemporal Transformer\)](#)

[Abstract](#)

[1. Introduction](#)

[2. Methodology](#)

[2.1 Model Components](#)

[2.2 Inference: Action-Controllable Video Generation](#)

[3. Experimental Results](#)

[설정](#)

[3.1 Scaling Results](#)

[3.2 Qualitative Results](#)

[3.3 Training Agents](#)

[3.4 Ablation Studies](#)

[4. Related Work](#)

[5. Conclusion and Future Work](#)

[읽으면서 짚어볼 만한 점](#)

Genie: Generative Interactive Environments

Background

World Model vs Video Model

- World model: 행동(action)을 입력받아 **다음 프레임을 예측**하는 모델
 - 학습에 (비디오 + 행동 라벨)이 필요해서, 행동 라벨이 있는 환경(게임 엔진, 로봇)에 한정됨
- Video model: 텍스트나 첫 프레임을 주면 **영상 전체를 생성**하는 모델
 - 제어가 영상 단위(video-level)라서 프레임마다 개입할 수 없음
- Genie는 비디오만으로 학습하면서 프레임 단위로 제어할 수 있는 모델

모델 종류	학습 데이터	제어 가능성
World Models	Video + Actions	Frame-level
Video Models	Video + Text	Video-level

모델 종류	학습 데이터	제어 가능성
Genie	Video만	Frame-level

VQ-VAE와 Discrete Token

- 연속적인 이미지/영상을 **codebook의 이산 코드(token)** 로 압축하는 autoencoder
- 영상을 token 시퀀스로 바꾸면 언어모델처럼 "다음 token 예측"으로 생성 문제를 풀 수 있음
- Genie는 이 구조를 두 군데에 씀
 - Video tokenizer: 프레임 → token
 - Latent action model: codebook 크기를 $|A|=8$ 로 제한해서 행동 종류를 8개로 한정

MaskGIT

- Token을 왼쪽부터 하나씩 뽑는 대신, **일부를 마스킹해 두고 여러 token을 병렬로 채우는** 생성 방식
- Genie의 dynamics model이 이 방식을 씀
- 추론 시 프레임당 25 MaskGIT step, temperature 2

ST-Transformer (Spatiotemporal Transformer)

- 영상은 token이 최대 $O(10^4)$ 개라서, 일반 transformer의 quadratic memory cost가 문제
- 한 블록 안에 spatial attention과 temporal attention을 번갈아 배치해서 해결
 - Spatial layer: 같은 시점 안의 $1 \times H \times W$ token끼리 attention
 - Temporal layer: 같은 위치 token을 T개 시점에 걸쳐 attention (causal mask 적용)
 - 가장 비싼 spatial attention의 비용이 **프레임 수에 선형**으로 증가
- FFW는 spatial/temporal 뒤에 하나만 두고 post-spatial FFW를 생략해서, 절약한 파라미터를 다른 곳에 배분 (성능이 크게 좋아졌다고 함)

Abstract

Genie는 라벨 없는 인터넷 영상으로 비지도 학습한 **첫 generative interactive environment**입니다. 텍스트, 합성 이미지, 사진, 스케치로 프롬프트를 주면 행동 제어가 가능한 가상 세계가 만들어집니다. 11B 파라미터 규모라서 foundation world model로 볼 수 있습니다. 구성은 세 가지입니다.

- spatiotemporal video tokenizer
- autoregressive dynamics model
- 간단하고 확장 가능한 latent action model

행동 라벨이 전혀 없는데도 프레임 단위로 조작할 수 있습니다. 여기서 배운 latent action space는 **처음 보는 영상의 행동을 모방하는 agent 학습**에도 쓸 수 있어서, generalist agent 학습의 길을 연다고 주장합니다.

1. Introduction

1) 문제의식

- 언어와 이미지 생성은 성숙했고 영상 생성도 scaling 효과가 보이지만, 영상 생성 모델의 상호작용성은 ChatGPT 같은 도구에 비해 크게 부족함
- 질문: 인터넷 영상으로 영상 하나가 아니라 **상호작용 가능한 경험 전체**를 생성할 수 있을까?

2) 제안: Generative Interactive Environments

- 단일 텍스트/이미지 프롬프트로 interactive environment를 생성하는 새로운 패러다임

- 학습 데이터: 공개 인터넷 게임 영상 200,000시간 이상 (행동/텍스트 라벨 없음)
- 제어: 학습된 latent action space를 통해 프레임 단위로 가능
- 핵심 설계: 모든 구성요소가 ST-transformer 기반
- 모델 크기를 40M → 2.7B로 키워 scaling 분석을 했고, 최종 모델은 11B

3) 일반성 검증

- **Platformers**: 2D 플랫폼 게임 영상 30,000시간으로 학습한 메인 모델
- **Robotics**: RT1 데이터셋의 행동 라벨 없는 로봇 영상으로 별도 모델 학습
- **Agent 학습**: 인터넷 영상에서 배운 latent action으로, 처음 보는 RL 환경의 영상에서 policy를 추론

2. Methodology

2.1 Model Components

학습 순서: Video tokenizer를 먼저 학습한 뒤, Latent action model(LAM, 픽셀 입력)과 Dynamics model(video token 입력)을 co-training합니다.

1) Latent Action Model (LAM)

- 인터넷 영상에는 행동 라벨이 거의 없으므로, **행동을 비지도로 학습**
- Encoder: 이전 프레임 $x_1:t$ 와 다음 프레임 x_{t+1} 을 입력받아 연속 latent action $\tilde{a}_t$ 를 출력
- Decoder: 이전 프레임들과 latent action을 입력받아 다음 프레임 $\hat{x}_{t+1}$ 예측
- VQ-VAE 목적함수로 학습하고, $|A| = 8$ 로 제한함
 - 사람이 플레이할 수 있고 제어 가능성도 강제하기 위한 설계
- Decoder는 과거 프레임을 볼 수 있으므로, $\tilde{a}_t$ 는 "과거와 미래 사이의 가장 의미 있는 변화"를 담게 됨
- **추론 때는 VQ codebook만 남기고 LAM 전체를 버림**. 학습 신호를 만들기 위한 장치일 뿐이고, 사용자의 행동이 그 자리를 대신함
- Causal mask 덕분에 전체 영상 $x_1:T$ 를 넣으면 행동 $\tilde{a}_1:T_{-1}$ 을 한 번에 생성

2) Video Tokenizer

- VQ-VAE로 T개 프레임 $x_1:T \in \mathbb{R}^{(T \times H \times W \times C)}$ 를 이산 표현 $z_1:T \in \mathbb{I}^{(T \times D)}$ 로 압축 (D는 이산 latent 공간 크기)
- 차별점: 기존 연구는 공간 압축만 했지만, Genie는 **encoder/decoder 모두에 ST-transformer**를 써서 시간적 동역학까지 인코딩
- Causal 구조 덕분에 각 z_t 에는 이전 모든 프레임의 정보가 들어 있음
- Phenaki의 C-ViViT도 시간을 고려하지만 비용이 프레임 수에 **quadratic**
 - Genie의 **ST-ViViT**는 선형이라 훨씬 효율적

3) Dynamics Model

- Decoder-only **MaskGIT** transformer (ST-transformer 기반)
- 입력: 과거 token $z_1:t-1$ 과 stopgrad 처리된 latent action $\tilde{a}_1:t-1$
- 출력: 다음 프레임 token $\hat{z}_t$
- 손실: 예측 token과 정답 token 사이의 cross-entropy
- 학습 시 입력 token을 **Bernoulli 마스킹 (비율 0.5~1 uniform)** 으로 랜덤하게 가림
- 행동을 프레임에 concat하는 기존 관행 대신 **additive embedding**으로 넣었더니 제어 가능성이 좋아짐

2.2 Inference: Action-Controllable Video Generation

추론 흐름

1. 사용자가 초기 프레임 x_1 을 프롬프트로 제공
2. Video tokenizer가 x_1 을 z_1 으로 변환
3. 사용자가 $[0, |A|)$ 범위의 정수로 latent action a_1 을 선택
4. VQ codebook에서 a_1 에 해당하는 벡터 $\tilde{a}_1$ 을 인덱싱
5. Dynamics model이 z_1 과 $\tilde{a}_1$ 로 z_2 를 예측
6. 이 과정을 autoregressive하게 반복
7. Tokenizer decoder가 token을 프레임으로 복원

참고로, 각 행동의 의미는 처음엔 알 수 없지만 **입력이 달라져도 상관됨**. 그래서 새 컨트롤러의 버튼 기능을 익히는 것과 비슷하다고 설명

3. Experimental Results

설정

Datasets

- **Platformers:** 플랫폼어 관련 키워드로 공개 영상을 필터링
 - 55M개 클립(16초, 10FPS, 160×90)에서 최종 6.8M개 클립(약 30k시간)으로 추림
- **Robotics:** RT1 데이터(약 130k 로봇 시연) + 시뮬레이션 데이터 + 209k 실제 로봇 에피소드
 - 행동 라벨은 쓰지 않고 영상으로만 취급

Metrics

- **Video fidelity:** FVD (Frechet Video Distance)
- **Controllability:** 논문이 새로 정의한 Δ_t PSNR

$$\Delta_t PSNR = PSNR(x_t, \hat{x}_t) - PSNR(x_t, \hat{x}'_t)$$

- $\hat{x}_t$: 정답 영상에서 추론한 latent action으로 생성한 프레임
- $\hat{x}'_t$: 랜덤하게 샘플링한 latent action으로 생성한 프레임
- 해석: 행동이 달라질 때 생성 결과가 정답에서 얼마나 멀어지는가를 본 것이므로, **값이 클수록 latent action의 영향이 커서 제어 가능성이 높음**
- 모든 실험에서 $t=4$ 로 보고

Training Details

구성요소	파라미터	주요 설정
Video tokenizer	200M	patch 4, codebook 32차원 × 1024 codes
LAM	300M	patch 16, codebook 32차원 × 8 codes
Dynamics model	10.1B	batch 512, 125k steps

- 전체 10.7B, 942B tokens, 256 TPUv5p로 학습
- 시퀀스 길이 16프레임, 10 FPS
- Dynamics model은 bfloat16과 QK norm으로 학습을 안정화

3.1 Scaling Results

- **모델 크기:** 40M → 2.7B로 키울수록 final training loss가 일관되게 감소
- **배치 크기:** 2.3B 모델에서 배치 128 → 256 → 448(1.9M → 3.8M → 6.6M tokens)로 키우면 loss가 비슷하게 개선
- 둘 다 키울수록 좋아지므로 최종 모델을 크게 학습 (웹사이트용 데모에서는 360p 복원용 decoder를 더 크게 학습)

3.2 Qualitative Results

Platformers-trained model (11B)

- **OOD 이미지 프롬프트**로 평가함
 - Imagen2 생성 이미지, 손그림 스케치, 실제 사진
 - 학습 분포와 많이 다른 입력에서도 캐릭터가 움직이는 게임 같은 동작이 나옴
- **Parallax 모사:** 같은 행동에서 전경은 많이 움직이고 배경은 조금만 움직임 → 3D 장면 구조를 이해한다는 창발적 능력

Robotics-trained model (2.5B)

- 테스트 FVD 82.7
- 텍스트와 행동 라벨 없이도 **down / up / left** 같은 일관된 행동을 학습
- 로봇 팔 조작뿐 아니라 **과자 봉지 같은 변형 물체의 상호작용**도 학습

3.3 Training Agents

- 처음 보는 RL 환경의 이미지로 다양한 trajectory 생성이 가능함
- **Latent action으로 모방 학습이 되는지 검증**
 1. 고정된 LAM으로 expert 영상에 latent action 라벨을 붙임
 2. 그 라벨로 policy(관측 → latent action)를 학습
 3. 소량의 (ground-truth 행동) 데이터로 latent action → 실제 행동 매핑을 학습
- 환경: 절차적 생성 2D 플랫폼머 **CoinRun** (Easy/Hard)
- 비교: 상한선(oracle BC, expert 행동 접근 가능)과 하한선(random agent)
- 결과: LAM 기반 policy가 **expert 샘플 200개만으로 oracle과 같은 성능**
- 해석: CoinRun을 본 적 없는 모델의 latent action이 일관되고 의미 있다는 증거

3.4 Ablation Studies

① LAM 입력: 픽셀 vs token (Table 2)

입력	데이터셋	FVD ↓	Δ PSNR ↑
Token-input	Platformers	38.8	1.33
Pixel-input (Genie)	Platformers	40.1	1.91
Token-input	Robotics	257.8	1.65
Pixel-input (Genie)	Robotics	136.4	2.07

- Token 입력은 Platformers에서 FVD가 약간 더 낮았지만 Robotics에서는 그 이점이 사라짐
- 두 환경 모두 제어 가능성(Δ PSNR)은 픽셀 입력이 더 좋았음
- 해석: Tokenization 과정에서 영상 동역학과 움직임 정보 일부가 사라지는 것으로 보임 → 원본 영상을 LAM에 넣는 편이 유리

② Tokenizer 구조 (Table 3)

구조	파라미터	메모리	FVD ↓	Δ PSNR ↑
ViT (공간만)	230M	0.3GB	114.5	1.39
C-ViViT	225M	1.6GB	272.7	1.37
ST-ViViT (ours)	205M	0.9GB	81.4	1.66

- ST-ViViT가 fidelity와 controllability에서 모두 최고이고, 메모리는 C-ViViT보다 훨씬 적음
- C-ViViT는 full space-time attention 때문에 메모리를 많이 쓰고 **과적합 경향**이 있어 강한 regularization이 필요했고, 이 때문에 성능이 낮았을 것으로 추정

4. Related Work

- **World models:** 기존에는 행동 라벨이 필요했음
 - GAIA-1(자율주행)과 UniSim(로봇 조작)은 텍스트와 행동 라벨을 모두 요구
 - Genie는 비디오만 사용
- **Video models:** 초기 프레임이나 텍스트를 주고 나머지를 예측하는 방식이라 제어가 영상 수준
 - Genie는 latent action space를 학습해서 사용자나 agent가 "플레이"할 수 있게 함
- **Playable Video Generation (PVG):** 도메인 특화된 정적 예제만 다루고, 이를 넘어 scaling하려면 구조 변경이 필요했음
 - Genie는 inductive bias를 덜어내고 일반적인 방법으로 만든 것
- **Environment generation (PCG):** 게임 레벨이나 코드를 생성하는 연구
 - Genie는 픽셀에서 직접 생성하므로 인터넷 영상의 다양성을 활용할 수 있음
- **Latent actions로 agent 학습:** 기존 연구들(VPT 등)은 사람이 라벨링한 행동 데이터로 inverse dynamics model을 학습해서 인터넷 영상에 행동 라벨을 붙이는 방식
 - Genie는 **latent action**으로 임의 환경의 policy를 추론해서, 비싸고 일반화가 어려울 수 있는 ground-truth 행동을 피함

5. Conclusion and Future Work

1) 결론

- 누구나, 어린이도 상상한 세계를 만들고 들어가 볼 수 있게 하는 새로운 형태의 생성 AI
- 비디오만으로 다양한 interactive environment를 생성할 수 있음

2) 한계

- 다른 autoregressive transformer처럼 **비현실적인 미래를 hallucinate**할 수 있음
- 기억이 **16프레임**으로 제한돼서 긴 호흡의 일관된 환경이 어려움
- 추론 속도가 약 **1FPS**라서 실시간 상호작용에는 부족

3) 향후 방향

- 더 많은 인터넷 영상으로 scaling
- Agent 학습으로의 확장 (RL의 핵심 한계인 "풍부하고 다양한 환경의 부족"을 해소)

4) 공개 여부 및 재현성

- 체크포인트, 학습 데이터셋, 데이터 예시는 **공개하지 않음**
- 대신 단일 TPU/GPU로 돌릴 수 있는 소규모 재현 예제를 Appendix F에 제공

읽으면서 짚어볼 만한 점

- 제어 가능성 지표 Δ PSNR은 논문이 직접 만든 지표이고, 사람 평가와의 상관은 본문에서 검증하지 않았음
→ "영향력 크기"만 재므로, **의미 있는 제어**인지는 정성 결과(Fig. 13의 down/up/left)에 의존
- Agent 실험은 CoinRun 하나이고, 이 환경이 Platformers와 비슷한 2D 플랫폼머라는 점을 감안해야 함
→ "임의 환경에 일반화된다"는 주장은 여기서도 과한 해석일 수 있습니다.
- 데이터와 가중치가 비공개라서, 스케일링 결과와 OOD 일반화는 외부에서 검증할 수 없음