

GPT

📅 date	2026년 9월 3일
# Num	9
🔗 논문 원문 링크	https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf
≡ 유형	BOAZ 학기 1주차 (1)

Improving Language Understanding by Generative Pre-Training

Improving Language Understanding by Generative Pre-Training

1. Abstract (문제 정의)
2. Introduction (연구 동기)
3. Related Work
4. Method — Framework 상세
5. Experiments 상세
 - NLI
 - QA
 - Classification / GLUE
6. Analysis (Discussion)
7. Conclusion

1. Abstract (문제 정의)

NLP 태스크(entailment, QA, similarity, classification)는 종류가 다양한데, 태스크별 레이블 데이터는 부족한 반면 unlabeled corpus는 풍부함.

이 비대칭을 활용해 "**generative pre-training + discriminative fine-tuning**" 2단계 프레임워크를 제안하고, task-aware input transformation으로 아키텍처 변경을 최소화하면서 12개 중 9개 태스크에서 SOTA 달성 (Story Cloze +8.9%p, RACE +5.7%p, MultiNLI +1.5%p).

2. Introduction (연구 동기)

- 지도학습은 대량의 라벨 데이터가 필요 → 라벨 부족 도메인에 적용 어려움
- Unlabeled data 활용의 두 가지 미해결 질문:
 1. 어떤 **optimization objective**가 전이에 효과적인가?
 - LM(language modeling), 기계번역, discourse coherence 등이 태스크마다 우열이 갈림
 2. 학습된 표현을 **target task**로 어떻게 전이할 것인가?
 - 기존엔 (a) 태스크별 아키텍처 수정, (b) 복잡한 학습 스킴, (c) 보조 목적함수 추가 등 제각각
- 이 논문의 답:
 - (1) 표준 LM objective
 - (2) Transformer + traversal-style 입력 변환

3. Related Work

계열	특징	이 논문과의 차이
Semi-supervised NLP (word2vec, GloVe)	단어/구 수준 통계만 전이	더 높은 수준(문장/문맥) 의미 포착 목표

계열	특징	이 논문과의 차이
Unsupervised pre-training (이미지 분야에서 먼저 검증, Erhan et al.이 정규화 효과 입증)	초기화 지점을 잘 잡는 것	NLP로 확장, Transformer 채택
Dai & Le, Howard & Ruder (LSTM 기반 LM pretrain → finetune)	가장 근접한 선행연구	LSTM은 단거리 의존성에 감힘 → Transformer가 장거리 구조 포착에 유리
Peters et al. (ELMo, feature-based)	pretrained 표현을 auxiliary feature로 사용, 태스크별 새 파라미터 필요	본 논문은 미세조정 시 최소 파라미터(Wy만 추가)로 전이
Auxiliary objective (Collobert & Weston, Rei)	보조 비지도 목적함수 추가	본 논문도 auxiliary LM을 쓰지만, 사전학습 자체가 이미 많은 언어지식을 담고 있음을 강조

4. Method — Framework 상세




Figure 1: **(left)** Transformer architecture and training objectives used in this work. **(right)** Input transformations for fine-tuning on different tasks. We convert all structured inputs into token sequences to be processed by our pre-trained model, followed by a linear+softmax layer.

1단계: 비지도 사전학습

$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta)$$

- k: context window 크기, 표준 언어모델링 목적함수를 SGD로 최적화
- 아키텍처: **12-layer decoder-only Transformer** (masked self-attention → 미래 토큰 못 봄)

$$h_0 = UW_e + W_p$$

$$h_l = \text{transformer}_{block}(h_{l-1}) \quad \forall l \in [1, n]$$

$$P(u) = \text{softmax}(h_n W_e^T)$$
 - U : context token 벡터
 - W_e : token embedding
 - W_p : **learned**(사인파 아님) position embedding

2단계: 지도 미세조정

$$P(y | x^1, \dots, x^m) = \text{softmax}(h_l^m W_y)$$

$$L_2(\mathcal{C}) = \sum_{(x,y)} \log P(y | x^1, \dots, x^m)$$

- 추가되는 파라미터는 오직 W_y + 구분자 토큰 임베딩뿐 (아키텍처 거의 그대로 재사용)

Auxiliary LM 결합

$$L_3(\mathcal{C}) = L_2(\mathcal{C}) + \lambda \cdot L_1(\mathcal{C}), \quad \lambda = 0.5$$

- 효과:
 - (a) 지도학습 일반화 향상
 - (b) 수렴 가속. 단, **작은 데이터셋에는 오히려 손해**(Ablation에서 확인)

Task-specific Input Transformation (traversal-style, Rocktäschel et al. 방식 차용)

모든 입력에 **(s)**, **(e)** 시작/끝 토큰 추가, 구조화 입력을 하나의 연속 시퀀스로 변환:

- **Entailment**: **premise \$ hypothesis** (premise, hypothesis를 구분자 \$로 concat)
- **Similarity**: 순서가 없는 두 문장 쌍이므로 **두 순서 모두** 넣어 각각 처리 후 두 표현을 element-wise 합산

- QA/상식추론: `[document; question; $; answer_k]` 를 답변 후보 개수만큼 만들어 각각 독립 처리 후 softmax로 정규화

5. Experiments 상세

사전학습 세팅

- 데이터: BooksCorpus (7000권+ 미출간 소설, 장거리 연속 텍스트가 핵심 — 1B Word Benchmark는 문장 단위로 셔플되어 있어 장거리 구조가 파괴됨, 그래서 안 씀)

Table 1: A list of the different tasks and datasets used in our experiments.

Task	Datasets
Natural language inference	SNLI [5], MultiNLI [66], Question NLI [64], RTE [4], SciTail [25]
Question Answering	RACE [30], Story Cloze [40]
Sentence similarity	MSR Paraphrase Corpus [14], Quora Question Pairs [9], STS Benchmark [6]
Classification	Stanford Sentiment Treebank-2 [54], CoLA [65]

- Perplexity 18.4 (token-level)
- 하이퍼파라미터: 768차원 hidden, 12 attention head, FFN 3072차원, Adam(max lr 2.5e-4, 2000 step linear warmup 후 cosine anneal to 0), 배치 64×512토큰 시퀀스, 100 epoch, dropout 0.1(residual/embedding/attention), modified L2 reg(w=0.01, Loshchilov & Hutter), 활성화함수 **GELU**, BPE 40,000 merges, ftfy + spaCy 토큰나이저

파인튜닝 세팅

- lr 6.25e-5, batch 32, 대부분 3 epoch로 충분, warmup 0.2%, $\lambda=0.5$

결과

태스크군	데이터셋	성능 향상
NLI	MNLI/SciTail/QNLI/SNLI	+1.5%p / +5%p / +5.8%p / +0.6%p (단, RTE는 56.0% < 이전 SOTA 61.7%)
QA/상식추론	RACE / Story Cloze	RACE 59.0(+5.7%p) / Story Cloze 86.5(+8.9%p)
유사도	STS-B / QQP	STS-B +1점, QQP +4.2%p
분류	CoLA / SST-2	CoLA 45.4(이전 35.0 대비 큰 도약), SST-2 91.3%
종합	GLUE	72.8 (이전 SOTA 68.9)

NLI

Table 2: Experimental results on natural language inference tasks, comparing our model with current state-of-the-art methods. 5x indicates an ensemble of 5 models. All datasets use accuracy as the evaluation metric.

Method	MNLI-m	MNLI-mm	SNLI	SciTail	QNLI	RTE
ESIM + ELMo [44] (5x)	-	-	<u>89.3</u>	-	-	-
CAFE [58] (5x)	80.2	79.0	<u>89.3</u>	-	-	-
Stochastic Answer Network [35] (3x)	<u>80.6</u>	<u>80.1</u>	-	-	-	-
CAFE [58]	78.7	77.9	88.5	<u>83.3</u>	-	-
GenSen [64]	71.4	71.3	-	-	<u>82.3</u>	59.2
Multi-task BiLSTM + Attn [64]	72.2	72.1	-	-	82.1	61.7
Finetuned Transformer LM (ours)	82.1	81.4	89.9	88.3	88.1	56.0

QA

Table 3: Results on question answering and commonsense reasoning, comparing our model with current state-of-the-art methods.. 9x means an ensemble of 9 models.

Method	Story Cloze	RACE-m	RACE-h	RACE
val-LS-skip [55]	76.5	-	-	-
Hidden Coherence Model [7]	77.6	-	-	-
Dynamic Fusion Net [67] (9x)	-	55.6	49.4	51.2
BiAttention MRU [59] (9x)	-	60.2	50.3	53.3
Finetuned Transformer LM (ours)	86.5	62.9	57.4	59.0

Classification / GLUE

Table 4: Semantic similarity and classification results, comparing our model with current state-of-the-art methods. All task evaluations in this table were done using the GLUE benchmark. (*mc*= Mathews correlation, *acc*=Accuracy, *pc*=Pearson correlation)

Method	Classification		Semantic Similarity			GLUE
	CoLA (mc)	SST2 (acc)	MRPC (F1)	STSB (pc)	QQP (F1)	
Sparse byte mLSTM [16]	-	93.2	-	-	-	-
TF-KLD [23]	-	-	86.0	-	-	-
ECNU (mixed ensemble) [60]	-	-	-	81.0	-	-
Single-task BiLSTM + ELMo + Attn [64]	35.0	90.2	80.2	55.5	66.1	64.8
Multi-task BiLSTM + ELMo + Attn [64]	18.9	91.6	83.5	72.8	63.3	68.9
Finetuned Transformer LM (ours)	45.4	91.3	82.3	82.0	70.3	72.8

6. Analysis (Discussion)




Figure 2: (left) Effect of transferring increasing number of layers from the pre-trained language model on RACE and MultiNLI. (right) Plot showing the evolution of zero-shot performance on different tasks as a function of LM pre-training updates. Performance per task is normalized between a random guess baseline and the current state-of-the-art with a single model.

- Layer 전이 수 실험:** 사전학습 layer를 몇 개까지 전이하느냐에 따라 성능이 계단식으로 증가 → MultiNLI에서 전체 전이 시 최대 9%p 향상. 각 layer마다 유용한 기능을 담고 있다는 근거.
- Zero-shot 행동 분석:** 파인튜닝 없이도 생성모델 자체로 태스크를 푸는 휴리스틱 설계
 - CoLA: 평균 토큰 log-prob로 문법성 점수화 후 threshold
 - SST-2: "very" 토큰을 붙이고 positive/negative 중 확률 높은 쪽 선택
 - RACE: 문서+질문 조건부로 가장 높은 평균 log-prob를 갖는 답 선택
 - DPRD(Winograd): 대명사를 두 후보로 치환 후 더 높은 log-prob 쪽 선택
 - 결과: 학습이 진행될수록 이 휴리스틱들의 성능이 꾸준히 상승 → 사전학습 자체가 태스크 관련 기능을 암묵적으로 학습한다는 증거. 또한 LSTM보다 Transformer의 zero-shot 분산이 작음(=inductive bias가 전이에 유리)

3. Ablation (Table 5)

Table 5: Analysis of various model ablations on different tasks. Avg. score is a unweighted average of all the results. (*mc*= Mathews correlation, *acc*=Accuracy, *pc*=Pearson correlation)

Method	Avg. Score	CoLA (mc)	SST2 (acc)	MRPC (F1)	STSB (pc)	QQP (F1)	MNLI (acc)	QNLI (acc)	RTE (acc)
Transformer w/ aux LM (full)	74.7	45.4	91.3	82.3	82.0	70.3	81.8	88.1	56.0
Transformer w/o pre-training	59.9	18.9	84.0	79.4	30.9	65.5	75.7	71.2	53.8
Transformer w/o aux LM	75.0	47.9	92.0	84.9	83.2	69.8	81.1	86.9	54.4
LSTM w/ aux LM	69.1	30.3	90.5	83.2	71.8	68.1	73.7	81.1	54.6

조건	Avg Score
Full (Transformer + aux LM)	74.7
Transformer, 사전학습 제거	59.9 (-14.8점)
Transformer, aux LM 제거	75.0 (대형 데이터셋만 손해, 즉 소형 데이터셋엔 aux LM 불필요)
LSTM + aux LM	69.1 (Transformer 대비 -5.6점, MRPC 한 곳만 LSTM이 우세)

7. Conclusion

- Task-agnostic 단일 모델로 생성적 사전학습 → 판별적 미세조정을 결합하면 아키텍처 커스터마이징 없이도 강력한 성능을 낼 수 있음을 실증
- Transformer(구조적 메모리)와 장거리 의존성을 가진 데이터(BooksCorpus)가 이 접근에 잘 맞는 조합이라는 시사점 제공
- 이후 GPT-2/3, BERT로 이어지는 pretrain-finetune 패러다임의 출발점