

RAG

📅 date	2026년 9월 10일
# Num	12
🔗 논문 원문 링크	https://arxiv.org/pdf/2005.11401
≡ 유형	BOAZ 학기 2주차 (2)

Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks

Background

Parametric vs Non-parametric Memory

- **Parametric memory:** 사전학습된 언어모델의 파라미터 안에 암묵적으로 저장된 지식 (예: GPT, BERT가 학습 중에 흡수한 사실 정보)
- **Non-parametric memory:** 모델 파라미터 밖에, 검색 가능한 형태로 존재하는 명시적 지식 저장소 (예: Wikipedia 문서 인덱스)
- Parametric-only 모델의 한계
 - 지식을 쉽게 수정/확장 불가능 (지식을 바꾸려면 재학습 필요)
 - 예측의 근거(provenance)를 제시하기 어려움
 - "hallucination"(사실이 아닌 내용을 그럴듯하게 생성) 발생
- RAG의 아이디어 → 두 메모리를 **결합**해서 서로의 단점을 보완
 - non-parametric memory: 지식을 직접 수정/확인 가능 → 해석가능성(interpretability) 확보
 - parametric memory: 유연한 언어 생성 능력 담당

관련 선행 연구와의 차별점

- REALM, ORQA: retriever + masked LM 결합, 그러나 **추출형(extractive) QA**에만 적용됨
- RAG: retriever + **seq2seq 생성 모델**을 결합해 QA를 넘어 요약, 대화, 사실검증 등 다양한 생성 태스크로 확장

1. Introduction

1) 배경: parametric-only 모델의 한계

- 사전학습 신경망 언어모델은 외부 메모리 접근 없이도 데이터로부터 상당한 깊이의 지식을 학습할 수 있음을 보여줌 → 파라미터화된 암묵적 지식 베이스처럼 작동
- 그러나 단점 존재
 - 메모리를 쉽게 확장하거나 수정할 수 없음
 - 예측에 대한 통찰(insight)을 직관적으로 제공하기 어려움

- "hallucination" 생성 가능성

2) Hybrid 모델의 등장

- Parametric memory + non-parametric(검색 기반) memory를 결합한 hybrid 모델이 위 문제들을 일부 해결 가능
 - 지식을 직접 수정/확장 가능
 - 접근된 지식을 검사(inspect)하고 해석(interpret) 가능
- REALM, ORQA → masked LM + 미분 가능한 retriever 결합, 유망한 결과를 보였으나 **open-domain extractive QA**만 탐구됨

3) 본 논문의 기여

- NLP의 "workhorse"인 **seq2seq 모델**에 hybrid parametric/non-parametric memory를 적용
- RAG 구성
 - Retriever: Dense Passage Retriever(DPR) 기반 → 입력에 조건화된 latent documents 제공
 - Generator: 사전학습된 seq2seq 모델(BART) → 입력 + 검색된 documents에 조건화해 출력 생성
- 두 컴포넌트를 확률 모델로 결합해 end-to-end 학습
- Latent documents를 top-K 근사로 marginalize
 - Per-output 방식: 생성된 시퀀스 전체에 대해 동일 문서가 책임진다고 가정
 - Per-token 방식: 토큰마다 서로 다른 문서가 책임질 수 있음
- T5나 BART처럼 어떤 seq2seq 태스크에도 파인튜닝 가능하며, generator와 retriever가 함께 학습됨

4) 선행 연구와의 관계

- Memory networks, stack-augmented networks, memory layers 등 → 특정 태스크 전용으로 처음부터 학습되는 non-parametric memory 아키텍처들이 다수 제안되어 왔음
- 본 연구의 차별점 → parametric·non-parametric 메모리 컴포넌트가 **모두 사전학습되어 있고 방대한 지식으로 미리 채워진** 세팅을 탐구
- 사전학습된 접근 메커니즘을 사용함으로써, 추가 학습 없이도 지식 접근 능력이 이미 갖춰져 있다는 점이 핵심

5) 주요 결과 요약

- Open Natural Questions, WebQuestions, CuratedTrec에서 최고 수준(state-of-the-art) 성능 달성
- TriviaQA에서 특화된 사전학습 목적함수를 사용하는 최근 접근법들을 크게 능가
- 이들이 추출형(extractive) 태스크임에도, 제약 없는(unconstrained) 생성 방식이 기존 추출형 접근법을 능가함을 발견
- 지식 집약적 생성 태스크(MS-MARCO, Jeopardy 질문 생성)에서 BART 베이스라인보다 더 사실적이고 구체적이며 다양한 응답 생성
- FEVER 사실 검증 → 강한 검색 지도(supervision)를 사용하는 최고 수준 파이프라인 모델과 4.3% 이내 차이로 근접
- 비파라메트릭 메모리를 교체함으로써 세계가 변화함에 따라 모델의 지식을 업데이트할 수 있음을 시연

2. Methods

1) 기본 세팅

- 입력 시퀀스 x 로 텍스트 문서 z 를 검색하고, 이를 타깃 시퀀스 y 생성 시 추가 문맥으로 사용
- 두 컴포넌트로 구성
 - Retriever $p_{\eta}(z|x)$: 쿼리 x 가 주어졌을 때 텍스트 passage에 대한 분포(top-K로 절단)를 반환, 파라미터 η
 - Generator $p_{\theta}(y_i|x, z, y_{1:i-1})$: 이전 토큰 문맥, 원본 입력, 검색된 passage를 바탕으로 현재 토큰 생성, 파라미터 θ
- Retriever와 generator를 end-to-end로 함께 학습하기 위해 검색된 문서를 **latent variable**로 취급

2.1 Models

1) RAG-Sequence Model

- 완전한 시퀀스를 생성하는 데 동일한 검색된 문서를 사용
- 검색된 문서를 하나의 단일 latent variable로 취급해 top-K 근사로 marginalize
- Top-K 문서를 검색한 뒤 각 문서에 대해 generator가 전체 출력 시퀀스 확률을 산출, 이를 marginalize

2) RAG-Token Model

- 타깃 토큰마다 다른 latent 문서를 뽑아 그에 따라 marginalize 가능
- Generator가 답을 생성할 때 여러 문서의 내용을 조합해 선택할 수 있게 해줌
- Top-K 문서를 검색한 뒤, 각 문서에 대해 다음 출력 토큰의 분포를 산출하고 marginalize, 이후 다음 토큰에서 이 과정을 반복

3) 분류 태스크로의 확장

- 타깃 클래스를 길이 1짜리 타깃 시퀀스로 간주하면 시퀀스 분류 태스크에도 RAG 사용 가능 → 이 경우 RAG-Sequence와 RAG-Token은 동일해짐

2.2 Retriever: DPR

- 검색 컴포넌트 $p_{\eta}(z|x)$ 는 DPR 기반
- Bi-encoder 아키텍처 사용
 - $d(z)$: BERT_BASE 기반 문서 인코더가 생성하는 문서의 밀집 표현
 - $q(x)$: BERT_BASE 기반 쿼리 인코더가 생성하는 쿼리 표현
 - $p_{\eta}(z|x) \propto \exp(d(z)^{\top} q(x))$
- 최고 확률의 상위 k개 문서를 구하는 것은 **Maximum Inner Product Search(MIPS)** 문제 → sub-linear 시간에 근사적으로 해결 가능
- DPR의 사전학습된 bi-encoder를 사용해 retriever를 초기화하고 문서 인덱스 구축
- 이 retriever는 TriviaQA, Natural Questions 질문에 대한 답을 포함하는 문서를 검색하도록 학습된 것
- 문서 인덱스를 non-parametric memory로 지칭

2.3 Generator: BART

- Generator $p_{\theta}(y_i|x, z, y_{1:i-1})$ 는 어떤 encoder-decoder로도 모델링 가능
- BART-large(4억 파라미터) 사용 — denoising 목적함수와 다양한 노이즈 함수로 사전학습된 seq2seq transformer

- 입력 x 와 검색된 콘텐츠 z 를 결합할 때 단순히 이 둘을 이어붙임(concatenate)
- BART generator 파라미터 θ 를 이후 parametric memory로 지칭

2.4 Training

- Retriever와 generator를 어떤 문서를 검색해야 하는지에 대한 직접적 지도(supervision) 없이 공동 학습
- 파인튜닝 학습 데이터 (x_j, y_j) 가 주어졌을 때, 각 타겟의 negative marginal log-likelihood $-\log p(y_j|x_j)$ 를 Adam으로 확률적 경사하강 최소화
- 학습 중 문서 인코더 $BERT_d$ 를 업데이트하는 것은 문서 인덱스를 주기적으로 재구축해야 해서 비용이 큼 (REALM 사전학습 방식과 유사)
- 저자들은 이 단계가 강한 성능을 위해 필요하지 않음을 발견 → 문서 인코더(및 인덱스)는 고정하고, 쿼리 인코더 $BERT_q$ 와 BART generator만 파인튜닝

2.5 Decoding

1) RAG-Token

- 표준적인 autoregressive seq2seq generator처럼 취급 가능
- Transition probability $p'(\theta(y_i|x, y_{1:i-1})) = \sum_{z \in \text{top-k}} (p(\cdot|x) \cdot p_\theta(z_i|x) p_\theta(y_i|x, z_i, y_{1:i-1}))$
- 표준 beam decoder에 그대로 대입해 디코딩 가능

2) RAG-Sequence

- Likelihood $p(y|x)$ 가 일반적인 토큰별 likelihood로 분해되지 않아 단일 beam search로 풀 수 없음
- 각 문서 z 마다 beam search를 실행해 $p_\theta(y_i|x, z, y_{1:i-1})$ 로 각 hypothesis를 스코어링 → hypothesis 집합 Y 산출 (일부는 모든 문서의 beam에 등장하지 않을 수 있음)
- Hypothesis y 의 확률을 추정하기 위해, y 가 등장하지 않은 문서 z 에 대해 추가 forward pass를 실행하고 generator 확률에 $p_\theta(z|x)$ 를 곱한 뒤 beam 전체에서 marginal 확률을 합산 → **"Thorough Decoding"**
- 출력 시퀀스가 길면 $|Y|$ 가 커져 많은 forward pass 필요 → 추가 근사로 x, z_i 로부터 beam search 중 생성되지 않은 y 에 대해 $p_\theta(y|x, z_i) \approx 0$ 으로 두면 후보 집합 Y 생성 이후 추가 forward pass 불필요 → **"Fast Decoding"**

3. Experiments

- 폭넓은 지식 집약적 태스크에서 RAG를 실험
- 모든 실험에서 non-parametric 지식 소스로 단일 Wikipedia 덤프(2018년 12월) 사용
- 각 Wikipedia 문서를 겹치지 않는 100단어 chunk로 분할 → 총 2,100만 개 문서
- 문서 인코더로 각 문서의 임베딩을 계산하고, FAISS 기반 Hierarchical Navigable Small World 근사로 단일 MIPS 인덱스 구축
- 학습 중 쿼리마다 top k 문서 검색, $k \in \{5, 10\}$ 을 학습에 사용하고 dev 데이터로 테스트 시점 k 결정

3.1 Open-domain Question Answering

- 질문과 답을 입력-출력 텍스트 쌍 (x, y) 로 취급, 답의 negative log-likelihood를 직접 최소화해 RAG 학습

- 비교 대상
 - 추출형(extractive) QA 패러다임: 검색된 문서에서 답을 span으로 추출, 주로 non-parametric 지식에 의존
 - "Closed-Book QA" 접근법: RAG처럼 답을 생성하지만 검색을 활용하지 않고 순수하게 parametric 지식에 의존
- 4개의 대표적 open-domain QA 데이터셋 사용: Natural Questions(NQ), TriviaQA(TQA), WebQuestions(WQ), CuratedTrec(CT)
- CT, WQ는 크기가 작아 NQ RAG 모델로 초기화한 뒤 학습(DPR 관행을 따름)
- 선행 연구와 동일한 train/dev/test split 사용, Exact Match(EM) 점수 보고
- TQA는 T5와 비교하기 위해 TQA Wiki test set에서도 평가

3.2 Abstractive Question Answering

- RAG는 단순 추출형 QA를 넘어 자유형식(free-form)의 abstractive text generation으로 질문에 답할 수 있음
- MSMARCO NLG task v2.1 사용 → 질문, 검색엔진에서 검색된 10개의 gold passage, 검색된 passage로부터 주석된 완전한 문장 답변으로 구성
- 제공된 passage는 사용하지 않고 질문과 답변만 사용 → MSMARCO를 open-domain abstractive QA 태스크로 취급
- MSMARCO에는 gold passage 접근 없이는 참조 답변과 일치하도록 답할 수 없는 질문 존재(예: "What is the weather in Volcano, CA?") → 이 경우 gold passage 없이는 성능이 낮아짐
- 일부 MSMARCO 질문은 Wikipedia만으로 답할 수 없음 → RAG는 이때 parametric 지식에 의존해 합리적인 응답 생성 가능

3.3 Jeopardy Question Generation

- Non-QA 세팅에서 RAG의 생성 능력을 평가하기 위해 open-domain 질문 생성 탐구
- 표준 open-domain QA 태스크의 짧고 단순한 질문 대신, 더 까다로운 Jeopardy 질문 생성 태스크 제안
- Jeopardy: 어떤 개체(entity)에 대한 사실로부터 그 개체를 추측하는 독특한 형식(예: "The World Cup" → "In 1986 Mexico scored as the first country to host this international sports competition twice.")
- SearchQA의 split 사용(train 100K, dev 14K, test 27K)
- 새로운 태스크이므로 비교를 위해 BART 모델을 직접 학습
- SQuAD로 튜닝된 Q-BLEU-1 지표로 평가 → 표준 지표보다 사람의 판단과 상관관계 높음
- 두 가지 인간 평가 수행: 생성의 factuality(사실성)와 specificity(구체성) 평가
 - Factuality: 신뢰할 수 있는 외부 소스로 진술을 뒷받침할 수 있는지 여부
 - Specificity: 입력과 출력 간 높은 상호 의존성
- Pairwise comparative evaluation 방식 사용 — 평가자에게 답변과 두 생성 질문(BART, RAG)을 보여주고 4개 선택지 중 선택하게 함

3.4 Fact Verification

- FEVER: 자연어 주장이 Wikipedia에 의해 지지(supported)되는지, 반박(refuted)되는지, 판단할 정보가 불충분(not enough info)한지 분류하는 태스크
- Wikipedia로부터 관련 근거를 검색한 뒤 이 근거를 바탕으로 주장의 진위를 추론해야 함
- FEVER는 검색 문제와 도전적인 entailment 추론 태스크가 결합된 형태 → RAG 모델이 생성이 아닌 분류를 다루는 능력을 탐구하기에 적절한 테스트베드
- FEVER 클래스 라벨(supports, refutes, not enough info)을 단일 출력 토큰에 매핑, claim-class 쌍으로 직접 학습
- 대부분의 다른 FEVER 접근법과 달리, 검색된 증거에 대한 supervision을 사용하지 않음
- 두 가지 변형 탐구: 표준 3-way 분류(supports/refutes/not enough info)와 2-way(supports/refutes) 분류, 두 경우 모두 label accuracy 보고

4. Results

4.1 Open-domain Question Answering

- 4개의 open-domain QA 태스크 전부에서 RAG가 새로운 최고 성능 달성(TQA는 T5-비교가능 split에서만)
- RAG는 "closed-book"(parametric-only) 접근법의 생성 유연성과 "open-book" 검색 기반 접근법의 성능을 결합
- REALM, T5+SSM과 달리, 값비싼 특화된 "salient span masking" 사전학습 없이도 강한 결과 달성
- RAG의 retriever는 DPR의 retriever로 초기화되며, 이는 Natural Questions와 TriviaQA에서 검색 supervision을 사용함
- BERT 기반 "cross-encoder"로 문서를 재순위화(re-rank)하는 DPR QA 시스템과 비교해도 우수 → re-ranker나 추출형 reader가 최고 성능에 필수적이지 않음을 시사
- 답을 추출 가능한 경우에도 생성이 갖는 이점
 - 답을 verbatim으로 포함하지 않지만 단서를 담은 문서도 정답 생성에 기여 가능(추출형 접근에서는 불가능)
 - 문서 전반에 걸친 더 효과적인 marginalization으로 이어짐
- 검색된 어떤 문서에도 정답이 없는 경우조차 RAG는 정답을 생성할 수 있음 → NQ에서 이런 경우 11.8% 정확도 달성(추출형 모델은 0%)

4.2 Abstractive Question Answering

- RAG-Sequence가 Open MS-MARCO NLG에서 BART를 Bleu 2.6점, Rouge-L 2.6점 앞섬
- Gold passage에 접근하는 최고 수준 모델에 근접하는 인상적인 결과 — 이 모델들은 (i) 참조 답변 생성에 필요한 특정 정보를 담은 gold passage에 접근하고, (ii) 많은 질문이 gold passage 없이는 답할 수 없으며, (iii) 모든 질문이 Wikipedia만으로 답 가능하지 않다는 점을 고려하면 더욱 그러함
- 정성적으로, RAG 모델이 BART보다 hallucination이 적고 사실적으로 올바른 텍스트를 더 자주 생성함을 발견
- RAG 생성이 BART 생성보다 더 다양함(4.5절에서 추가로 다룸)

4.3 Jeopardy Question Generation

- RAG-Token이 RAG-Sequence보다 Jeopardy 질문 생성에서 더 나은 성능, 둘 다 Q-BLEU-1에서 BART를 능가
- 인간 평가 결과(BART와 RAG-Token 생성 452쌍 대상)
 - BART가 더 사실적이라고 평가된 경우: 7.1%
 - RAG가 더 사실적이라고 평가된 경우: 42.7%
 - 둘 다 사실적: 17%
 - → 최고 수준 생성 모델 대비 RAG의 효과성을 명확히 입증
 - 평가자들은 RAG 생성이 훨씬 더 구체적이라고도 평가
- Jeopardy 질문은 흔히 두 가지 별개 정보를 포함 → RAG-Token이 여러 문서의 내용을 조합해 응답을 생성할 수 있어 가장 좋은 성능을 보인 것으로 추정
- "Hemingway"를 입력으로 한 예시(Figure 2): "Sun" 생성 시 "The Sun Also Rises"를 언급하는 문서 2의 posterior가 높고, "A Farewell to Arms" 생성 시 문서 1의 posterior를 지배
- 각 책 제목의 첫 토큰이 생성된 후 문서 posterior가 평탄해지는 흥미로운 관찰 → generator가 특정 문서에 의존하지 않고도 제목을 완성할 수 있음을 시사, 즉 parametric 지식만으로 제목 완성이 충분함
- BART-only 베이스라인에 부분 디코딩을 입력해 이 가설을 뒷받침하는 근거 확인 → parametric 메모리와 non-parametric 메모리가 함께 작동함을 보여줌: non-parametric 컴포넌트가 생성을 안내하고, parametric 메모리에 저장된 구체적 지식을 이끌어냄

4.4 Fact Verification

- 3-way 분류에서 RAG 점수는 최고 수준 모델과 4.3% 이내 차이 — 이 모델들은 도메인 특화 아키텍처와 상당한 엔지니어링을 갖춘 복잡한 파이프라인 시스템이며 중간 검색 supervision으로 학습됨(RAG는 이를 필요로 하지 않음)
- 2-way 분류에서는, gold evidence 문장이 주어진 상태로 RoBERTa를 학습해 주장을 분류하는 모델과 비교했을 때 2.7% 이내의 정확도 달성 — RAG는 주장(claim)만 제공받고 스스로 증거를 검색함에도 불구하고
- RAG가 검색한 문서와 FEVER의 gold evidence로 주석된 문서 간 일치 여부 분석 → 최상위 검색 문서가 gold article인 경우 71%, 상위 10개 검색 문서 중 gold article이 포함된 경우 90%

4.5 Additional Results

1) Generation Diversity

- Diversity-promoting decoding 없이도, distinct n-gram 대 total n-gram 비율을 계산해 생성 다양성 조사
- RAG-Sequence의 생성이 RAG-Token보다 더 다양, 둘 다 BART보다 훨씬 더 다양함(별도의 diversity-promoting decoding 불필요)

2) Retrieval Ablations

- 검색 메커니즘의 효과성을 평가하기 위해 학습 중 retriever를 고정하는 ablation 실행 → 학습된 검색(learned retrieval)이 모든 태스크에서 결과를 향상시킴
- RAG의 dense retriever를 단어 중첩(word overlap) 기반 BM25 retriever와 비교
 - FEVER에서는 BM25가 가장 우수 → FEVER claim이 entity-centric이라 단어 중첩 기반 검색에 잘 맞기 때문으로 추정

- 다른 모든 태스크, 특히 매우 중요한 Open-Domain QA에서는 미분 가능한 검색이 성능을 향상시킴

3) Index hot-swapping

- Non-parametric memory 모델(RAG 등)의 장점 → 테스트 시점에 지식을 쉽게 업데이트 가능
- T5, BART 같은 parametric-only 모델은 세계 변화에 맞춰 행동을 업데이트하려면 추가 학습이 필요
- 2016년 12월 Wikipedia 덤프(DrQA)로 인덱스를 구축해, 최신 결과에 쓰인 2018년 12월 인덱스와 출력 비교
- 2016~2018년 사이 교체된 82명의 세계 지도자 목록을 준비, "Who is {position}?" 템플릿으로 NQ RAG 모델에 각 인덱스로 질의
- 2016년 지도자에 대해 2016년 인덱스 사용 시 70% 정확, 2018년 지도자에 대해 2018년 인덱스 사용 시 68% 정확
- 인덱스가 불일치하는 경우 정확도는 낮음(2018년 인덱스+2016년 지도자 12%, 2016년 인덱스+2018년 지도자 4%)
- → 비파라메트릭 메모리를 단순히 교체하는 것만으로 RAG의 세계 지식을 업데이트할 수 있음을 보여줌

4) Effect of Retrieving more documents

- 모델은 5개 또는 10개의 검색된 latent 문서로 학습되며, 이 둘 사이에 유의미한 성능 차이는 관찰되지 않음
- 테스트 시점에 검색 문서 수를 조정하는 유연성이 있으며, 이는 성능과 실행시간에 영향을 줌
- 테스트 시점에 더 많은 문서를 검색할수록 RAG-Sequence의 Open-domain QA 결과는 단조적으로 향상되지만, RAG-Token의 성능은 10개 검색 문서에서 정점을 찍음
- 더 많은 문서를 검색할수록 RAG-Token의 Rouge-L은 높아지나 Bleu-1은 낮아짐(RAG-Sequence는 이 효과가 덜 뚜렷함)

5. Related Work

5.1 Single-Task Retrieval

- 선행 연구는 검색이 개별적으로 고려됐을 때 다양한 NLP 태스크에서 성능을 향상시킴을 보여줌: open-domain QA, 사실 검증(fact checking), 사실 완성(fact completion), 장문 QA, Wikipedia 문서 생성, 대화, 번역, 언어모델링 등
- 본 연구는 개별 태스크에서의 검색 통합 성공 사례들을 통합해, 단일 검색 기반 아키텍처가 여러 태스크에서 강한 성능을 달성할 수 있음을 보여줌

5.2 General-Purpose Architectures for NLP

- 검색을 사용하지 않고도 범용 아키텍처가 큰 성공을 거둠
- 단일 사전학습 언어모델이 파인튜닝 후 GLUE 벤치마크의 다양한 분류 태스크에서 강한 성능 달성
- GPT-2는 단일한 left-to-right 사전학습 언어모델이 판별(discriminative) 및 생성(generative) 태스크 모두에서 강한 성능을 달성할 수 있음을 보임
- BART와 T5는 양방향 attention을 활용하는 단일 사전학습 encoder-decoder 모델을 제안해 판별/생성 태스크 모두에서 더 강한 성능 달성
- 본 연구는 사전학습된 생성 언어모델을 증강하는 검색 모듈을 학습함으로써, 단일하고 통합된 아키텍처로 가능한 태스크의 범위를 확장하고자 함

5.3 Learned Retrieval

- 정보 검색 분야에서 문서를 검색하도록 학습하는 연구가 상당히 존재, 최근에는 본 연구와 유사한 사전학습 신경 언어모델을 활용
- 일부 연구는 검색, 강화학습, 또는 latent variable 접근(본 연구와 동일)을 사용해 특정 다운스트림 태스크(예: QA)에 도움이 되도록 검색 모듈을 최적화
- 이러한 성공들은 서로 다른 검색 기반 아키텍처와 최적화 기법을 활용해 단일 태스크에서 강한 성능을 달성하는 반면, 본 연구는 단일 검색 기반 아키텍처가 다양한 태스크에서 파인튜닝되어 강한 성능을 낼 수 있음을 보여줌

5.4 Memory-based Architectures

- 본 연구의 문서 인덱스는 신경망이 attend할 수 있는 대규모 외부 메모리로 볼 수 있음 — memory networks와 유사
- 동시대 연구는 원본 텍스트를 검색하는 대신 입력 내 각 개체에 대한 학습된 임베딩을 검색하는 방식 사용
- 다른 연구는 사실 임베딩(fact embedding)에 attend함으로써 대화 모델이 사실적인 텍스트를 생성하는 능력을 향상
- 본 연구 메모리의 핵심 특징 → 분산 표현이 아닌 **원본 텍스트**로 구성됨 → (i) 사람이 읽을 수 있어 해석가능성 제공, (ii) 사람이 쓸 수 있어 문서 인덱스를 편집함으로써 모델의 메모리를 동적으로 업데이트 가능
- 이러한 접근은 지식 집약적 대화에서도 사용된 바 있음(다만 end-to-end 학습 검색이 아닌 TF-IDF로 얻은 검색된 텍스트에 조건화)

5.5 Retrieve-and-Edit approaches

- 본 방법은 retrieve-and-edit 스타일 접근법과 일부 유사성 공유 — 주어진 입력에 대해 유사한 학습 입출력 쌍을 검색한 뒤 편집해 최종 출력을 제공하는 방식
- 이러한 접근법은 기계번역, 시맨틱 파싱 등 여러 도메인에서 성공적임이 입증됨
- 본 연구의 차이점 → 검색된 항목을 가볍게 편집하는 것에 대한 강조가 적은 대신, 여러 검색된 콘텐츠 조각의 내용을 종합(aggregate)하는 데 중점을 두고, latent retrieval을 학습하며, 관련 학습 쌍이 아닌 증거 문서(evidence document)를 검색
- RAG 기법이 이러한 세팅에서도 잘 작동할 수 있으며, 유망한 future work가 될 수 있음을 언급

6. Discussion

- Parametric 및 non-parametric memory에 접근 가능한 hybrid 생성 모델 제시
- RAG 모델이 open-domain QA에서 최고 수준 결과를 달성함을 보임
- 사람들은 순수하게 parametric인 BART보다 RAG의 생성을 선호하며, RAG가 더 사실적이고 구체적이라고 평가함을 발견
- 학습된 검색 컴포넌트에 대한 철저한 조사를 수행해 그 효과성을 검증했고, 재학습 없이 검색 인덱스를 hot-swap해 모델을 업데이트하는 방법을 시연
- Future work → 두 컴포넌트를 처음부터 공동으로 사전학습할 수 있는지 조사하는 것이 유익할 수 있음 (BART와 유사한 denoising 목적함수 또는 다른 목적함수 사용)

- 본 연구는 parametric·non-parametric 메모리가 어떻게 상호작용하고 이를 가장 효과적으로 결합하는 방법에 대한 새로운 연구 방향을 열며, 다양한 NLP 태스크에 적용될 수 있는 가능성을 보여줌

Broader Impact

1) 긍정적 측면

- 실제 사실적 지식(이 경우 Wikipedia)에 더 강하게 근거하고 있어 "hallucination"이 적고 더 사실적인 생성 제공, 더 큰 통제력과 해석가능성 제공
- 다양한 시나리오에서 사회에 직접적인 이익을 줄 수 있음(예: 의학 인덱스를 부여해 open-domain 질문에 답하게 하거나, 사람들이 업무에서 더 효과적일도록 돕는 것)

2) 잠재적 부작용

- Wikipedia나 다른 외부 지식 소스는 결코 완전히 사실적이거나 편향에서 완전히 자유롭지 않을 것
- RAG가 언어모델로 사용될 수 있다는 점에서 GPT-2와 유사한 우려가 유효함(정도는 다소 덜하더라도) — 뉴스나 소셜미디어에서 남용·조작·오해를 유발하는 콘텐츠 생성, 타인 사칭, 스팸/피싱 콘텐츠 자동 생산 등에 사용될 가능성
- 고도화된 언어모델은 향후 수십 년간 다양한 직업의 자동화로 이어질 수 있음
- 이러한 위험을 완화하기 위해, AI 시스템을 오해를 유발하는 콘텐츠 및 자동화된 스팸/피싱과 맞서 싸우는 데 활용할 수 있음