

SAM

📅 date	2026년 9월 24일
≡ 유형	BOAZ 학기 4주차 (2)

[SAM: Segment Anything](#)

[Background](#)

[핵심 용어](#)

[기존 방식 vs SAM](#)

[CLIP과의 연결](#)

[Abstract](#)

[1. Introduction](#)

[2. Segment Anything Task](#)

[3. Segment Anything Model](#)

[4. Segment Anything Data Engine](#)

[5. Segment Anything Dataset](#)

[6. Segment Anything RAI Analysis](#)

[지리·소득 분포 \(Table 1\)](#)

[사람 분할의 공정성 \(Table 2\)](#)

[옷 분할 \(Table 6, Appendix C\)](#)

[7. Zero-Shot Transfer Experiments](#)

[7.1 Zero-Shot Single Point Valid Mask Evaluation](#)

[7.2 Zero-Shot Edge Detection](#)

[7.3 Zero-Shot Object Proposals](#)

[7.4 Zero-Shot Instance Segmentation](#)

[7.5 Zero-Shot Text-to-Mask](#)

[7.6 Ablations \(23개 데이터셋, 단일 중심점 프로토콜\)](#)

[8. Discussion](#)

[Appendix 핵심 요약](#)

[A. 모델과 태스크 상세](#)

[B. 자동 마스크 생성 상세](#)

[C. RAI 추가 상세](#)

[D. 실험 구현 상세](#)

[E. 사람 평가 설계](#)

[F, G. Dataset / Model Card, 어노테이션 가이드라인](#)

[읽으면서 짚어둘 점](#)

SAM: Segment Anything

Background

핵심 용어

용어	의미
Segmentation mask	이미지에서 특정 객체가 차지하는 픽셀 영역을 표시한 이진 마스크
Promptable segmentation	"무엇을 분할할지"를 프롬프트(점, 박스, 마스크, 텍스트)로 지정하면 그에 맞는 마스크를 반환하는 태스크
Interactive segmentation	사용자가 클릭을 반복하며 마스크를 점점 다듬는 기존 방식. SAM은 이 학습 방식을 차용하되 단일 프롬프트에서도 valid한 마스크 를 내는 것이 목표
IoU / mIoU	예측 마스크와 정답 마스크의 교집합/합집합 비율. mIoU는 그 평균

용어	의미
Focal loss / Dice loss	마스크 학습용 손실. focal은 어려운 픽셀에 가중, dice는 영역 겹침 기반
NMS	겹치는 중복 예측 중 신뢰도 높은 것만 남기는 후처리
MAE	Masked Autoencoder. 이미지 일부를 가리고 복원하는 self-supervised 사전학습
Modal vs amodal mask	modal은 눈에 보이는 부분만, amodal은 가려진 부분까지 포함한 마스크
Oracle 평가	SAM이 낸 3개 마스크 중 정답과 가장 잘 맞는 것 을 골라 채점하는 방식. 모호성이 점수에 미치는 영향을 보기 위한 분석용

기존 방식 vs SAM

- 기존 segmentation: 태스크가 고정됨 (semantic / instance / panoptic 각각 별도 모델). 학습 때 본 태스크만 수행
- 기존 interactive segmentation: 사람이 여러 번 클릭해야 최종 마스크가 나옴
- SAM: **프롬프트 하나만 줘도 즉시 valid한 마스크**를 반환하고, 프롬프트를 바꾸는 것만으로 **학습하지 않은 새 태스크**(엣지 검출, 객체 제한, 인스턴스 분할 등)에 전이
- NLP의 "next token prediction + prompt engineering"과 같은 발상을 segmentation으로 옮긴 것

CLIP과의 연결

- 논문이 "zero-shot transfer"라는 용어를 **CLIP의 용법을 따른다**고 명시 (unseen 데이터셋/태스크로의 일반화)
- 텍스트 프롬프트는 **CLIP의 text encoder를 그대로** 사용
- 학습은 CLIP **image** embedding으로, 추론은 CLIP **text** embedding으로 하는 트릭 (Section 7.5). CLIP이 두 임베딩 공간을 정렬해 뒀기 때문에 가능
- "CLIP이 DALL-E의 구성요소로 쓰이듯, SAM도 더 큰 시스템의 구성요소로 쓰이길" 원한다는 것이 논문의 철학

Abstract

- Segment Anything(SA) 프로젝트: 이미지 분할을 위한 새로운 **태스크, 모델, 데이터셋**
- 효율적인 모델을 데이터 수집 루프에 넣어, 라이선스가 있고 프라이버시를 지킨 **1,100만 장** 이미지에 **10억 개 이상**의 마스크를 만들 (기존 최대 규모를 압도)
- 모델은 **promptable**하게 설계·학습되어 새 이미지 분포와 태스크로 zero-shot 전이 가능
- 다수 태스크에서 평가한 결과 zero-shot 성능이 인상적이며, 종종 기존 완전 지도학습 결과와 경쟁하거나 능가
- 모델(SAM)과 데이터셋(SA-1B)을 공개: <https://segment-anything.com>

1. Introduction

1) 배경

- 웹 규모 데이터로 사전학습한 LLM이 zero-shot/few-shot 일반화를 보임. 이런 "foundation model"은 학습 때 본 분포를 넘어 일반화하며, 보통 **prompt engineering**으로 구현됨
- 컴퓨터 비전에서는 CLIP, ALIGN이 대표적. 대조학습으로 text/image encoder를 정렬하면 텍스트 프롬프트로 zero-shot 일반화가 가능하고, DALL-E 같은 시스템의 부품으로도 쓰임
- 그러나 비전에는 이 범위를 벗어나는 문제가 많고, 그 다수는 **학습 데이터가 풍부하지 않음**

2) 이 논문의 목표

- **이미지 분할을 위한 foundation model** 구축. 프롬프트로 지시할 수 있는 모델을 넓은 데이터셋에서 사전학습하고, 프롬프트 엔지니어링으로 새 분포의 downstream 분할 문제를 푼다
- 성공은 세 요소에 달림. 각각에 대응하는 질문:
 1. 어떤 **태스크**가 zero-shot 일반화를 가능하게 하는가?
 2. 대응하는 **모델** 아키텍처는?
 3. 이 태스크와 모델을 뒷받침할 **데이터**는?
- 세 질문은 서로 얽혀 있어 통합적으로 해결해야 함

3) 각 요소 요약

요소	내용
Task (§2)	promptable segmentation: 어떤 프롬프트가 와도 valid mask 반환. 프롬프트가 모호해도 (셔츠 vs 그것을 입은 사람) 그중 적어도 하나 에 대해 합리적인 마스크를 내면 됨
Model (§3)	무거운 image encoder(1회) + 가벼운 prompt encoder / mask decoder. 같은 image embedding을 여러 프롬프트에 재사용. 임베딩이 있으면 웹 브라우저에서 약 50ms
Data engine (§4)	웹에 마스크 데이터가 자연적으로 풍부하지 않으므로, 모델이 어노테이션을 들고 새 데이터로 모델을 개선하는 순환 구조
Dataset (§5)	SA-1B: 11M 이미지, 1.1B 마스크. 기존 어떤 분할 데이터셋보다 마스크가 400배 많음

4) 이 논문의 나머지 주장

- Responsible AI (§6): SA-1B는 지리·소득 면에서 기존보다 다양하고, SAM은 사람 그룹 간 성능이 대체로 비슷
- 실험 (§7): 새로 구성한 23개 데이터셋에서 단일 점 프롬프트만으로 고품질 마스크 생성. 엣지 검출, 객체 제안, 인스턴스 분할, 텍스트 → 마스크 예비 실험까지 프롬프트 엔지니어링으로 수행
- 공개: SA-1B는 연구용 라이선스, SAM은 Apache 2.0

2. Segment Anything Task

1) 태스크 정의

- NLP의 next token prediction이 사전학습과 downstream 전이를 동시에 해결하듯, 분할에서도 **사전학습 태스크 = 전이 방법**이 되는 태스크를 정의
- **프롬프트** = 이미지에서 무엇을 분할할지 알려주는 모든 정보 (전경/배경 점, 대략적인 박스나 마스크, 자유 텍스트 등)
- **Promptable segmentation task** = 임의의 프롬프트가 주어졌을 때 **valid한 마스크**를 반환
- "valid"의 의미: 프롬프트가 모호해 여러 객체를 가리킬 수 있어도, 그중 **하나에 대해 합리적인 마스크**면 충분. 모호한 프롬프트에 일관된 응답을 내는 언어모델과 비슷한 요구

2) 사전학습

- 학습 샘플마다 프롬프트 시퀀스(점, 박스, 마스크)를 **시뮬레이션**하고 예측을 정답과 비교. interactive segmentation에서 가져온 방식
- 차이점: interactive segmentation은 충분한 입력 뒤 **최종적으로** 정답 마스크를 내는 것이 목표지만, SAM은 **모든 프롬프트에 대해 항상 valid한 마스크**를 내야 함
- 이 덕분에 모호성이 있는 상황(자동 어노테이션 포함)에서도 사전학습 모델이 쓸 만함
- 다만 이 태스크를 잘 푸는 것은 어렵고, 특수한 모델링과 손실 함수 설계가 필요

3) Zero-shot transfer

- 프롬프트만 잘 설계하면 downstream 태스크를 풀 수 있음
- 예: 고양이 박스 검출기가 있으면, 그 박스를 SAM 프롬프트로 주는 것만으로 **고양이 인스턴스 분할**이 됨
- 논문은 5가지 예시 태스크를 §7에서 실험

4) 기존 multi-task 시스템과의 차이

- 기존 multi-task 시스템(semantic + instance + panoptic 통합 모델 등): 학습과 테스트 태스크가 **같은 고정 집합**
- SAM: 추론 시 **학습하지 않은 새 태스크**를 수행. 예를 들어 객체 검출기와 **결합**해 인스턴스 분할을 수행하는 등 더 큰 시스템의 **구성요소**로 동작
- 이는 task generalization의 한 형태

5) Discussion

- prompting과 composition은 하나의 모델을 확장 가능한 방식으로 쓰게 해 주는 강력한 도구 (CLIP이 DALL-E의 text-image 정렬 부품이 되는 것과 유사)
- interactive segmentation 모델은 사람 사용자를 염두에 두고 설계되지만, promptable segmentation 모델은 알고리즘 시스템의 일부로도 조립될 수 있음

3. Segment Anything Model

1) 전체 구조 (Figure 4)

- 세 구성요소: **image encoder**, 유연한 **prompt encoder**, 빠른 **mask decoder**
- 핵심 아이디어: 무거운 연산(image encoder)은 이미지당 **한 번만**, 프롬프트마다 도는 부분(prompt encoder + mask decoder)은 **가볍게**. 같은 image embedding을 여러 프롬프트에 재사용해 비용을 amortize

2) Image encoder

- **MAE로 사전학습한 ViT**를 고해상도 입력에 맞게 최소한으로 수정해 사용
- 이미지당 한 번 실행되며, 프롬프트 입력 전에 미리 계산 가능
- 기본 모델은 ViT-H

3) Prompt encoder

프롬프트 종류	분류	인코딩 방식
점, 박스	Sparse	positional encoding + 프롬프트 타입별 학습 임베딩의 합
텍스트	Sparse	CLIP의 기성 text encoder 사용
마스크	Dense	컨볼루션으로 임베딩한 뒤 image embedding에 원소별로 더함

4) Mask decoder

- Transformer decoder 블록을 수정한 구조 + dynamic mask prediction head (DETR, MaskFormer 계열에서 영감)
- 수정된 decoder 블록: 프롬프트 self-attention + **양방향 cross-attention** (프롬프트 → 이미지 임베딩, 이미지 임베딩 → 프롬프트)로 **모든 임베딩을 갱신**
- 두 블록을 돌린 뒤 image embedding을 upsample하고, MLP가 output token을 **dynamic linear classifier**로 바꿔 각 위치의 전경 확률을 계산

5) 모호성 해결 (Resolving ambiguity)

- 출력이 하나면 모호한 프롬프트에서 여러 valid 마스크를 **평균내 버림**
- 해결: 프롬프트 하나당 **마스크 3개**를 동시에 예측 (중첩 마스크는 보통 whole / part / subpart 세 단계면 충분)
- 학습 시에는 3개 중 **loss가 가장 작은 것에만** backprop
- 마스크 순위를 매기기 위해 각 마스크의 예상 IoU(confidence score)도 예측

6) 효율성

- image embedding이 미리 계산되어 있으면 prompt encoder + mask decoder는 브라우저에서 CPU로 **약 50ms**
- 덕분에 실시간 interactive 프롬프팅이 가능

7) 손실과 학습

- 마스크 손실: **focal loss + dice loss**의 선형 결합
- 기하학적 프롬프트 혼합으로 학습하며, interactive setup을 흉내내 **마스크당 11 라운드**로 프롬프트를 무작위 샘플링
- 이 방식 덕분에 SAM이 data engine에 자연스럽게 들어감

4. Segment Anything Data Engine

웹에 분할 마스크는 풍부하지 않으므로, **모델과 데이터를 함께 키우는 data engine**을 구축. 세 단계.

단계	방식	마스크 수	이미지당 마스크 수	마스크당 어노테이션 시간
① Assisted-manual	전문 어노테이터가 SAM 기반 브라우저 도구로 전경/배경 클릭 + brush/eraser로 다듬음	4.3M (120k 이미지)	20 → 44	34초 → 14초
② Semi-automatic	자동 검출된 confident 마스크를 미리 채워두고, 어노테이터는 나머지 객체만 라벨링	+5.9M (180k 이미지), 누적 10.2M	44 → 72 (자동 마스크 포함)	34초 (자동 제외)
③ Fully automatic	사람 개입 없이 모델이 생성	1.1B (11M 이미지)	약 100	-

① Assisted-manual

- 시작 시점의 SAM은 공개 분할 데이터셋으로 학습. 데이터가 쌓이면 **새로 수집한 마스크만으로** 재학습
- 마스크가 늘수록 image encoder를 **ViT-B → ViT-H**로 키우고 구조도 발전. 총 **6회** 재학습
- 14초는 COCO 마스크 어노테이션보다 **6.5배 빠르고**, extreme points 기반 박스 라벨링보다 **2배만 느림**
- "stuff"와 "thing"을 구분하지 않고 자유롭게 라벨링. 이름이나 설명은 수집하지 않음. 중요도 순으로 라벨링하고, 30초 넘게 걸리면 다음 이미지로 이동하도록 권장

② Semi-automatic

- 목적은 마스크의 **다양성** 증가. 덜 눈에 띄는 객체에 어노테이터를 집중시킴
- 1단계 마스크로 "object"라는 단일 범주의 **박스 검출기**를 학습해 confident 마스크를 먼저 검출
- 모델은 5회 재학습

③ Fully automatic

- 가능해진 이유 두 가지: (1) 앞 단계에서 다양한 마스크가 충분히 모여 모델이 크게 개선됨 (2) **ambiguity-aware 모델**이 있어 모호한 경우에도 valid한 마스크 예측 가능
- 절차:
 1. **32×32 규칙 격자**의 점으로 프롬프트, 점마다 마스크 세트 예측 (part/subpart/whole이 함께 나옴)
 2. **IoU 예측**으로 confident 마스크 선택
 3. **stable** 마스크만 선택: 확률 맵을 0.5-6, 0.5+6로 threshold했을 때 결과가 비슷하면 stable
 4. **NMS**로 중복 제거
 5. 작은 마스크 품질을 위해 **확대한 여러 crop**도 처리
- 11M 전체 이미지에 적용해 총 **1.1B** 마스크 생성

5. Segment Anything Dataset

1) 이미지

- 사진 작가와 직접 일하는 제공업체에서 **11M장** 라이선스 취득. 평균 **3300×4950** 고해상도
- 저장/접근성 문제로 **짧은 변 1500px로 다운샘플**해 공개 (그래도 COCO 약 480×640보다 훨씬 큼)
- **얼굴과 차량 번호판은 블러** 처리

2) 마스크

- 총 1.1B개 중 **99.1%가 완전 자동 생성**. 따라서 자동 마스크의 품질이 핵심
- 이 분석과 §7 실험에서 자동 마스크가 고품질이고 학습에 효과적이라는 결론이 나와, **SA-1B는 자동 생성 마스크만 포함**

3) 마스크 품질

- 무작위 500장(약 50k 마스크)을 전문 어노테이터가 SAM 도구와 brush/eraser로 **교정** → 자동 마스크와 교정본 사이의 IoU 계산
- **94%의 쌍이 IoU 90% 초과, 97%가 75% 초과**
- 비교: 기존 연구가 추정한 어노테이터 간 일치도는 **85~91% IoU**

4) 마스크 속성 (Figure 5, 6)

항목	결과
객체 중심 분포	사진작가 편향(중앙 쏠림)은 모든 데이터셋에 존재. SA-1B는 LVIS, ADE20K처럼 모서리 커버리지가 넓고 , COCO와 Open Images는 중앙 편향이 더 강함
규모	2위인 Open Images 대비 이미지 11배, 마스크 400배 . 이미지당 마스크는 36배 . 가장 가까운 ADE20K도 3.5배 적음
상대적 마스크 크기	이미지당 마스크가 많아 작고 중간 크기 마스크 비중이 큼
모양 복잡도 (concavity)	마스크 크기 분포를 통제된 뒤 비교하면 다른 데이터셋과 대체로 유사

6. Segment Anything RAI Analysis

지리·소득 분포 (Table 1)

- 이미지에 지오태그가 없어서, 이미지별 **캡션에서 NER로 위치를 추정**해 국가를 매핑 (COCO와 Open Images는 Flickr API로 추정)

지역	SA-1B	COCO	Open Images
Europe	49.8%	34.2%	36.2%
Asia & Oceania	36.2%	11.4%	14.3%
North America	7.7%	48.3%	42.8%
Latin America & Carib.	3.5%	3.1%	5.0%
Africa	2.8%	3.0%	1.7%

소득 수준	SA-1B	COCO	Open Images
High income	54.0%	89.1%	87.5%
Middle income	45.0%	10.5%	12.0%
Low income	0.9%	0.4%	0.5%

- SA-1B는 유럽, 아시아·오세아니아, 중간 소득 국가 비중이 상대적으로 높음
- 그러나 **Africa와 저소득 국가는 모든 데이터셋에서 과소 대표**
- Africa를 포함한 모든 지역이 최소 **2,800만 마스크** (기존 데이터셋 전체 마스크 수의 10배)
- 이미지당 마스크 수는 지역과 소득에 관계없이 94~108로 일관됨

사람 분할의 공정성 (Table 2)

- 평가: 지각된 성별 표현, 연령대(MIAP 데이터셋), 피부 톤(Fitzpatrick 스케일, 비공개 데이터셋)별 mIoU. 1점/3점 프롬프트
- 결과:
 - 성별: feminine 54.4 vs masculine 55.7 (1점), 신뢰구간 겹침
 - 연령: older 62.9, middle 54.5, young 54.2 (1점). **older vs middle만** 신뢰구간이 안 겹침
 - 피부 톤: 그룹 간 유의한 차이 없음
- 저자들의 해석: 결과는 태스크의 성격에서 비롯된 것일 수 있으며, **더 큰 시스템의 구성요소로 쓰일 때는 편향이 생길 수 있음**

옷 분할 (Table 6, Appendix C)

- 옷을 입은 사람의 인지된 성별에 따라 1점 프롬프트에서 **feminine 76.3 vs masculine 81.0**으로 신뢰구간이 겹치지 않음 → **편향의 징후**. 3점에서는 격차가 줄어들
- 연령 그룹 간 차이는 유의하지 않음
- 저자들은 사용자에게 이 한계를 유의하라고 권고

7. Zero-Shot Transfer Experiments

"zero-shot transfer"는 CLIP의 용법을 따라 **학습 때 보지 못한 데이터셋과 태스크**에서 평가한다는 뜻. 5개 태스크 중 4개는 학습 태스크와 크게 다름. 별도 명시가 없으면 **MAE 사전학습 ViT-H** 인코더 + SA-1B(자동 마스크만)로 학습한 모델을 사용.

7.1 Zero-Shot Single Point Valid Mask Evaluation

1) 설정

- 단일 전경 점으로 객체를 분할. 점 하나가 여러 객체를 가리킬 수 있어 **원래 ill-posed**이고, 정답 마스크는 가능한 모든 마스크를 열거하지 않음 → 자동 지표가 불안정
- 그래서 mIoU에 더해 ****사람 평가(1~10점)****를 병행
- 점은 정답 마스크의 "중심"(내부 distance transform 최댓값)에서 샘플링. 기본은 **가장 confident한 마스크 하나만** 평가
- 비교 baseline: **RITM** (23개 데이터셋에서 가장 강한 interactive segmenter), 추가로 SimpleClick, FocalClick
- 23개 데이터셋: 수중, 현미경, X-ray, 자율주행, 항공, egocentric, 그림, 시뮬레이션 등 다양한 도메인

2) 결과 (Figure 9)

평가	결과
자동(mIoU), 1점	SAM이 23개 중 16개 에서 RITM보다 높음 (최대 약 47 IoU 차이)
Oracle 사용 시	3개 마스크 중 정답에 맞는 것을 고르면 SAM이 모든 데이터셋 에서 RITM을 능가 → 모호성이 자동 지표에 미치는 영향이 큼
사람 평가	대부분 RITM보다 뚜렷하게 높음 . SAM의 평균 평점은 7~9 구간 ("객체가 식별되고 오류가 작고 드물"에 해당). ambiguity-unaware(단일 출력) SAM은 이보다 낮지만 RITM보다는 높음
점 개수 증가	1→9점으로 갈수록 방법 간 격차가 줄어들 (SAM은 고IoU 영역에 최적화되지 않음)
랜덤 첫 점	중심 대신 랜덤 첫 점을 쓰면 SAM과 baseline의 격차가 오히려 커짐

- DRAM, IBD처럼 자동 지표에서 SAM이 뒤지는 데이터셋도 사람 평가에서는 **더 높은 점수**

7.2 Zero-Shot Edge Detection

1) 접근

- BSDS500(엣지 검출)로 평가. SAM은 엣지 맵 학습도, BSDS 이미지 접근도 없음
- **16×16 격자 점 프롬프트** → 768개 마스크(점당 3개) → NMS → 마스크 확률 맵에 **Sobel 필터** → 엣지 NMS로 세션화

2) 결과 (Table 3)

방법	ODS	OIS	AP	R50
HED (BSDS500으로 학습)	.788	.808	.840	.923
DETR (SOTA)	.840	.858	.896	.930
Sobel	.539	-	-	-
Canny	.600	.640	.580	-
Felz-Hutt	.610	.640	.560	-
SAM (zero-shot)	.768	.786	.794	.928

- 기존 zero-shot 방법(Sobel, Canny, Felz-Hutt)을 크게 앞섬. BSDS500으로 학습한 초기 딥러닝 방법 HED에도 근접
- SAM은 **정답에 없는 엣지까지 더 많이 예측** → R50(재현율)은 높지만 정밀도가 낮음. BSDS500 특유의 "어떤 엣지를 억제할지"의 편향을 학습하지 않았기 때문

7.3 Zero-Shot Object Proposals

1) 접근

- LVIS v1의 **AR@1000**으로 평가. 자동 마스크 생성 파이프라인을 약간 수정해 마스크를 proposal로 출력
- Baseline: ViTDet-H (cascade Mask R-CNN). 이 baseline은 "Detector Masquerading as Proposal generator"로 알려진, AR을 **계** **입할 수 있는** 강한 비교 대상

2) 결과 (Table 4)

방법	all	small	med.	large	freq.	com.	rare
ViTDet-H	63.0	51.7	80.8	87.0	63.1	63.3	58.3
SAM – single out.	54.9	42.8	76.7	74.4	54.7	59.8	62.0
SAM	59.3	45.5	81.6	86.9	59.1	63.9	65.8

- 전체는 ViTDet-H가 최고. 그러나 SAM은 **medium, common, rare**에서 앞섬
- ViTDet-H가 우세한 small/frequent는 LVIS에서 학습했기 때문에 **LVIS 어노테이션 편향**을 배울 수 있는 영역
- **Ambiguity-unaware(단일 출력) SAM은 모든 AR 지표에서 크게 하락** → 프롬프트당 여러 마스크를 내는 설계가 다양한 스케일의 proposal 재현율에 기여

7.4 Zero-Shot Instance Segmentation

1) 접근

- 완전 지도학습 **ViTDet-H가 낸 박스**를 SAM에 프롬프트로 입력 (SAM을 인스턴스 분할기의 분할 모듈로 조립)

2) 결과 (Table 5, Figure 11)

	COCO AP	LVIS AP
ViTDet-H	51.0	46.6
SAM	46.5	44.7

- AP는 ViTDet이 높지만 **LVIS에서는 격차가 작음**
- 시각적으로는 SAM 마스크의 **경계가 더 선명**. 사람 평가(1~10)에서는 **SAM 8.1 vs ViTDet 7.9**로 SAM이 높음 (LVIS GT 8.6, COCO GT 7.6)
- 저자들의 가설: ViTDet은 데이터셋의 **어노테이션 편향**(예: COCO의 낮은 GT 품질, LVIS의 구멍 없는 폴리곤과 amodal 마스크)을 배워 AP를 높이는 반면, zero-shot인 SAM은 그런 편향을 이용할 수 없음

7.5 Zero-Shot Text-to-Mask

- **Proof-of-concept**. 이 실험만 SAM의 학습 절차를 텍스트 인식이 가능하도록 수정하되 **새 텍스트 어노테이션은 불필요**
- 방법: 면적 100² 초과 마스크마다 **CLIP image embedding**을 추출하고, 학습 때 이를 **첫 프롬프트**로 사용
- 핵심 관찰: CLIP의 image/text 임베딩이 정렬되어 있으므로 **학습은 image embedding으로, 추론은 text embedding으로** 하면 됨

- 결과: "a wheel", "beaver tooth grille" 같은 단순/미묘한 텍스트 프롬프트로 분할 가능. 텍스트만으로 잘못된 객체를 고를 때는 **점 프롬프트**를 추가하면 교정됨

7.6 Ablations (23개 데이터셋, 단일 중심점 프로토콜)

실험	결과
Data engine 단계	각 단계가 mIoU를 올림. 세 단계를 모두 쓸 때는 자동 마스크가 압도적이라 수동/반자동을 10배 오버샘플링 해야 최고 성능이었으나 학습이 복잡해짐
자동 마스크만 사용	전체 데이터 사용 대비 약 0.5 mIoU 낮은 정도 → 기본 설정으로 채택
데이터 규모	0.1M 이미지에서는 큰 하락. 1M 이미지(약 10%, 약 100M 마스크) 면 전체와 비슷 → 실용적 설정
Image encoder 크기	ViT-B → ViT-H는 큰 향상이나 ViT-L → ViT-H는 미미 . 더 키우는 것은 지금은 효과적으로 보이지 않음

8. Discussion

Foundation model

- "넓은 데이터로 대규모 학습되어 다양한 downstream 태스크에 적용 가능한 모델"이라는 정의(Bommasani et al.)에 부합하지만, 분할은 **컴퓨터 비전의 일부일 뿐**이므로 범위가 본질적으로 제한적
- Bommasani et al.은 self-supervised 학습을 강조하지만, SAM은 MAE로 **초기화만** self-supervised이고 능력의 대부분은 **대규모 지도학습**에서 나옴. data engine으로 어노테이션을 확장할 수 있다면 지도학습도 효과적

Compositionality

- CLIP이 DALL·E의 부품이 되듯, SAM도 다른 시스템의 구성요소가 되길 기대
- 예: MCC가 SAM으로 관심 객체를 분할해 단일 RGB-D에서 3D 재구성. 웨어러블 기기의 **시선(gaze) 점**을 프롬프트로 주는 응용

Limitations

- 가는 구조를 놓치고, 작은 분리된 조각을 **환각**하기도 함. 확대(zoom-in)하는 계산량 큰 방법만큼 경계가 선명하지 않음
- 점이 많이 주어진다면 전용 interactive segmentation 방법이 더 나을 것 (SAM은 범용성과 폭을 위해 설계됨)
- 프롬프트 처리는 실시간이지만, **무거운 image encoder를 쓰면 전체는 실시간이 아님**
- text-to-mask는 탐색적이며 견고하지 않음
- semantic/panoptic segmentation을 구현할 **간단한 프롬프트 설계법이 불분명**
- 도메인 특화 도구가 각 도메인에서는 SAM을 능가할 것

Conclusion

- 새 태스크(promptable segmentation), 모델(SAM), 데이터셋(SA-1B)으로 분할을 foundation model 시대로 끌어올리려는 시도. SAM이 foundation model 지위를 얻음. 커뮤니티에서 어떻게 쓰이는지에 달림

Appendix 핵심 요약

A. 모델과 태스크 상세

Image encoder

- MAE 사전학습 **ViT-H/16**, 14×14 windowed attention + 균등 간격의 **global attention 블록 4개** (ViTDet 방식)
- 입력 **1024×1024** (리스케일 + 패딩) → 16배 다운스케일된 **64×64** 임베딩. 1×1 conv로 256 채널로 줄이고 3×3 conv, 각 conv 뒤에 LayerNorm
- 인코더 FLOPs는 이미지당 한 번만 쓰이므로 크게 잡아도 됨

Prompt encoder

- 점 = positional encoding + (전경/배경) 학습 임베딩
- 박스 = **좌상단 코너**와 **우하단 코너** 두 임베딩 (각각 positional encoding + 코너 종류 학습 임베딩)
- 마스크 프롬프트는 입력보다 4배 낮은 해상도로 넣고, 2×2 stride-2 conv 두 번(채널 4, 16) + 1×1 conv(256)로 임베딩. 마스크 프롬프트가 없으면 "no mask" 학습 임베딩을 더함

Mask decoder (Figure 14)

- 프롬프트 임베딩 집합에 **학습되는 output token**을 추가 (ViT의 [class] 토큰과 유사)

- decoder 레이어 1개가 하는 일 4단계: (1) 토큰 self-attention (2) 토큰 → 이미지 cross-attention (3) 토큰별 MLP (4) 이미지 → 토큰 cross-attention
- **2층** decoder, 임베딩 차원 256, MLP 내부 2048, cross-attention에서는 Q/K/V 채널을 128로 줄임, 8 heads, dropout 0.1
- 모든 attention 층에서 **positional encoding**을 **image embedding**에 더하고, **원본 프롬프트 토큰을 다시 더해줌** → 프롬프트의 위치와 종류 정보에 강하게 의존
- 마지막에 image embedding을 **4배 upsample**(transposed conv 2개), output token을 3층 MLP에 통과시킨 벡터와 **점별 곱**으로 마스크 산출
- 전체 decoder 연산량은 image encoder의 1% 미만

모호성 처리 디테일

- 기본 3개 마스크 + IoU 예측 head (별도 output token)
- **프롬프트가 여러 개면 모호성이 줄어** 3개 마스크가 비슷해지므로, 이때는 **네 번째 output token**의 마스크만 사용. 이 네 번째 마스크는 단일 프롬프트에서는 절대 반환되지 않음

손실과 학습

- focal : dice = **20 : 1**. IoU head는 MSE 손실, 가중치 1.0. decoder 각 층의 auxiliary deep supervision은 도움이 안 되어 사용 안 함
- 첫 프롬프트: 같은 확률로 **점 또는 박스**. 점은 정답 마스크에서 균등 샘플링, 박스는 정답의 bounding box에 좌표별 노이즈(표준편차 = 변이의 10%, 최대 20px)
- 이후 점은 이전 예측과 정답의 **오류 영역**에서 샘플링 (false negative면 전경점, false positive면 배경점). 이전 마스크(threshold 전 logits)도 프롬프트로 함께 입력
- 총 **11 iteration** = 초기 프롬프트 1 + 반복 샘플 점 8 + 새 정보 없이 마스크만 다듬는 2회
- **AdamW**, lr 8e-4, 90k iteration(약 2 epoch), batch 256, 256 GPU, weight decay 0.1, drop path 0.4, layer-wise lr decay 0.8, **데이터 증강 없음**. 정답의 90% 초과를 덮는 마스크는 학습에서 제외

B. 자동 마스크 생성 상세

- **Cropping**: 전체 이미지 32×32 격자 + **확대 crop 20개** (2×2와 4×4 겹치는 윈도우, 각각 16×16, 8×8 격자). crop 경계에 닿는 마스크 제거. NMS는 crop 내부와 crop 간 두 단계, 임계값 0.7
- **Filtering** (세 가지):
 - 예측 IoU ≥ **88.0**
 - **stability**: logit을 -1과 +1로 threshold한 두 마스크의 IoU ≥ **95.0**
 - 이미지의 **95% 이상**을 덮는 마스크 제거
- **Postprocessing**: 마스크의 약 4%에 작은 spurious 조각, 약 4%에 작은 구멍 → **면적 100px 미만** 조각 제거, 구멍 채움
- 자동 생성용 특수 SAM: 수동 + 반자동 데이터만으로, 더 오래(177,656 iter) + large-scale jitter, 점과 마스크 프롬프트만 사용(박스 제외), 마스크당 점 4개 샘플, decoder **3층**

C. RAI 추가 상세

- 지리 정보는 이미지 캡션에서 ELMo 기반 NER로 추정 (예: "Georgia"의 모호성 등 편향 가능성). 추정 위치와 캡션은 **공개하지 않음** (제공업 체 조건)
- COCO는 학습셋의 약 24%(19,562장), Open Images는 약 18%(493,517장)에 대해서만 Flickr API로 위치를 확보
- 사람 공정성 평가용 GT 마스크는 Open Images 마스크 중 MIAP 박스와 1% 이내로 일치하는 3.9k개

D. 실험 구현 상세

- **D.1 점 평가**: 23개 데이터셋에서 마스크가 15k 초과인 데이터셋은 약 10k 마스크가 되도록 서브샘플. 첫 점은 경계에서 가장 먼 점, 이후는 오류 영역 경계에서 가장 먼 점. N = 1, 2, 3, 5, 9점. 데이터셋별 mIoU를 구한 뒤 23개를 평균. baseline은 각 저자 공개 최대 모델을 설정 변경 없이 사용
- **D.2 엡지**: 위 방법 그대로. IoU/stability 필터링 없음
- **D.3 proposal**: 1000개 근처의 마스크를 위해 **64×64 격자, NMS 0.9**(평균 약 900개), crop과 IoU/stability 필터 제거. 1000개 초과 시 confidence와 stability의 평균으로 순위. single-output 버전은 128×128, NMS 0.95
- **D.4 인스턴스 분할**: ViTDet 박스 + **추가 refinement 1회** (가장 confident한 예측 마스크를 박스와 함께 다시 입력). SAM은 LVIS에서 modal(가려진 부분 제외) 마스크를 내지만 LVIS GT는 amodal이라 어노테이션 방식과 어긋나는 사례 존재
- **D.5 텍스트**: CLIP ViT-L/14@336px 사용. 수동/반자동 단계의 마스크(면적 100² 이상)로 학습. 마스크 주변 박스를 1~2배 확장해 336×336으로 crop → **50% 확률로 마스크 바깥 픽셀을 0으로** + 마지막 층에서 masked attention으로 output token이 마스크 내부만 보

게 함. 120k iteration, batch 128

- **D.6 잠재 공간 탐색:** 마스크 임베딩(마스크 내부 image embedding의 평균)의 최근접 이웃이 모양과 의미 면에서 **불완전하지만 유사성**을 보임. SAM이 명시적 semantic supervision 없이도 어느 정도 의미를 담는다는 예비 증거

E. 사람 평가 설계

- 목적: IoU의 두 한계 보완 — (1) 모호한 입력에서 정답과 다른 객체의 valid 마스크가 불이익을 받음 (2) 정답 마스크의 체계적 편향(경계 품질, modal/amodal)을 도메인 내 학습 모델이 이용 가능
- 7개 데이터셋(LVIS v0.5, VISOR, DRAM, IBD, NDD20, OVIS, iShape) 각 1000 마스크, 데이터셋당 30명의 어노테이터. 각 마스크는 한 명이 평가 (초기 테스트에서 5명 평가 시 평균 표준편차 0.83)
- 세 가지 기준: 실제 객체에 대응하는가 / 경계가 깨끗한가 / 입력(점, 박스)에 대응하는가 → 1~10점
- 통계 검정(paired t-test, paired bootstrap): SAM이 RITM과 단일 출력 SAM보다 높다는 결과가 **모든 데이터셋에서 유의** (Table 8)

F, G. Dataset / Model Card, 어노테이션 가이드라인

- SA-1B는 **자동 생성 마스크만** 공개. data engine의 수동 마스크는 비공개. 이미지 약 2k장은 테스트용으로 보류. 캡션은 공개하지 않음
- 어노테이터는 **케냐 기반 130명**, 벤더가 정한 시급으로 보상 (Certified B Corporation)
- 학습 비용: **A100 256장, 68시간**, 약 6,963 kWh, CO₂ 약 2.8톤
- SAM 라이선스는 Apache 2.0, SA-1B는 연구용 라이선스
- 가이드라인(Fig. 19, 20): 마스크 평점 기준 — 1점(무슨 객체인지 불명), 2~4점(객체는 식별되나 품질 매우 나쁨), 5~6점(주요 오류 존재), 7~9점(작고 드문 오류), 10점(오류 없음)

읽으면서 짚어줄 점

- **품질 검증의 순환성:** 자동 마스크가 고품질이라는 근거(94%가 IoU 90% 초과)는 **SAM 기반 도구로 교정한 결과**와의 비교임. 교정자가 모델 출력을 출발점으로 삼으므로 실제 독립적인 정답과의 일치도보다 **낙관적**일 수 있음. 어노테이터 간 일치도(85~91%)와의 비교도 조건이 다름
- **사람 평가의 독립성:** 평가자가 data engine 어노테이션을 수행한 **같은 회사** 소속이고, 데이터셋당 30명이 각자 다른 마스크를 평가하는 설계. 모델 출력이 익숙한 스타일일 가능성이 있음 (평가 자체는 모델 이름을 모르는 블라인드에 가깝지만 논문에서 명시적으로 다루지는 않음)
- **Oracle의 해석:** oracle 결과는 정답을 알아야 고를 수 있으므로 **실제 배포에서 달성 불가**. "모호성 때문에 자동 지표가 낮게 나온다"는 설명의 근거이지, SAM의 실제 성능 증명은 아님
- **Table 4와 본문의 미세한 불일치:** 본문은 "large 객체에서 ViTDet-H를 능가"라고 쓰지만, 표에서는 large가 **ViTDet 87.0 vs SAM 86.9**로 사실상 동률(오히려 ViTDet이 0.1 높음)
- **"zero-shot"의 엄밀성:** SA-1B에 수중/egocentric 등이 없다는 것은 "저자들이 아는 한"이라는 단서가 붙음. 또 인스턴스 분할은 **ViTDet 박스가 필요**하므로 SAM 단독 zero-shot이 아니라 지도학습 검출기와의 조합
- **엣지 검출 비교:** SAM은 SOTA(EDETR)에 크게 못 미침. 논문도 R50이 높은 대신 정밀도를 희생했다고 밝힘. "zero-shot 방법 중 최고"이지 "엣지 검출에 유용"이라는 뜻은 아님
- **Segment Anything ≠ Recognize Anything:** SA-1B의 마스크에는 **클래스나 텍스트가 없음**. semantic/panoptic 분할은 프롬프트 설계 법조차 불명확하다고 스스로 인정. 텍스트 프롬프트는 CLIP 정렬에 얹은 예비 실험 수준
- **공정성 분석의 범위:** 성별/연령/피부 톤 결과는 "유의한 차이 없음"이지만 신뢰구간이 넓은 그룹이 있고(older, 피부 톤 5~6), 옷 분할에서는 성별 격차가 실제로 확인됨. Africa와 저소득 국가 과소 대표 문제는 SA-1B도 해결하지 못함
- **위치 추정 방법:** 지리 분포가 캡션 NER 기반이라 오류 가능성이 있고, 추정 결과 자체는 공개되지 않아 **재현 검증이 어려움**

멀티모달 스터디 관점에서는 CLIP과 SAM을 나란히 놓고 보면 좋습니다. 둘 다 "프롬프트로 태스크를 지정한다"는 철학을 공유하지만, CLIP은 **대조학습으로 웹 데이터에서** 배우고, SAM은 **data engine으로 스스로 만든 마스크 데이터에서** 지도학습한다는 점이 대비됩니다. 원하면 Mask decoder의 cross-attention 흐름(Figure 14)을 코드 수준으로 풀어 드리겠습니다.